

第二章 根据京东评论数据分析城市消费偏好结构

2.1 研究背景与意义

在当前数字经济深度发展的时代背景下，电子商务平台积累的海量用户生成内容（UGC），特别是线上消费评论，已成为研究区域经济活动、社会文化特征与消费者行为模式的宝贵经验数据源。京东（JD.com）作为中国主流电商平台之一，其上亿级的用户群体及其产生的超过五万条（以本研究数据样本为例）真实商品评论，为我们提供了一个独特的观测窗口，用以审视中国广阔地域内不同城市群体展现出的消费偏好与结构差异。这种差异，不仅仅是购买力的体现，更深层次地反映了各地区独特的经济发展水平、社会文化背景、基础设施完善度乃至居民的生活方式与价值取向，共同塑造了我们所称的“城市消费性格”。

因此，本研究的核心议题聚焦于“城市消费偏好结构与性格”的量化分析与深度解读。旨在超越传统的宏观统计数据或小范围抽样调查的局限性，利用大数据与计算社会科学的方法，系统性地、多维度地探究中国不同省市区域的消费特性。研究尤其关注服装品类，将其作为一个典型案例，深入剖析具体消费行为模式，期望回答以下核心问题：中国不同区域的消费行为呈现出怎样的空间分布格局与梯度特征？不同层级的城市（如一线城市、区域中心等）在消费能力、价值追求、情感表达上有何显著差异？经济（如 GDP、薪资、房价）、社会（如互联网普及率）等宏观因素如何与微观消费行为（如客单价、品类偏好、关键词倾向）相互作用？

为了实现上述研究目标，本研究将构建一个从数据获取到深度分析的完整技术与分析框架。首先，通过网络爬虫技术（如利用 DrissionPage 库）从京东平台获取大规模、高时效性的真实用户评论数据。其次，建立一套严谨的数据预处理流程，涵盖数据清洗、整合与标准化，确保分析结果的有效性与可靠性。再次，综合运用多种数据分析与可视化技术（包括 Pandas、Matplotlib、Seaborn、Plotly 等工具），从以下几个层面展开探索：

- **空间维度：**通过地理信息系统（GIS）与热力图技术，可视化评论数量与情感得分的省际分布，识别消费活跃度与满意度的空间集聚或分异特征。
- **价值维度：**应用 RFM（Recency, Frequency, Monetary）模型，对不同省份的用户群体进行价值分层，识别核心、成长、潜力等不同类型的市场区域。
- **能力维度：**结合外部宏观经济数据（薪资、房价等），利用箱线图、雷达图等方式，对比分析核心城市群（如京、沪、粤）的消费能力与消费结构，探讨经济基础对其消费行为的影响。
- **偏好维度：**通过关联网络分析、主成分分析（PCA）聚类以及词云技术，挖掘不同省份与特定服装品类的关联强度，识别具有相似消费关键词模式的城市群，并直观呈现核心城市消费者的关注焦点与诉求差异。

2.2 爬虫架构与实现 — 逐步解析 京东评论.py

2.2.1 技术栈与整体流程

驱动层

DrissionPage + Chromium：轻量浏览器驱动，可直接抓 DevTools Network 包。源代码中明确使用了 `from DrissionPage import Chromium, ChromiumOptions`。DrissionPage 是一个基于 Python 的网页自动化工具，它封装了浏览器操作，能够执行 JavaScript，处理动态加载的内容，并且可以直接监听和获取网络请求数据包（DevTools Network），这对于抓取由 Ajax 加载的评论数据至关重要。Chromium 是其驱动的浏览器内核。**优势**：DrissionPage 结合了 Requests 的便捷性和浏览器驱动的动态内容处理能力。与 Selenium 相比，它在抓取 DevTools Network 包方面更为直接，对于需要监听特定 Ajax 请求的场景（如本项目的评论加载）非常高效。相对于 Scrapy，对于中小型、需要快速原型验证的项目，DrissionPage 的上手门槛和配置复杂度更低。**适用场景**：非常适合需要与页面有一定交互（如点击、滚动）并精确捕获由 JavaScript 动态发起的网络请求的爬虫任务。

逻辑层

a) 一次性手动登录，保留会话

- 代码实现：driver_login(tab1, 'https://passport.jd.com/uc/login') 函数中，tab.get() 打开登录页后，通过 input('请手动登录后按回车继续...') 提示用户手动操作。脚本会等待用户操作完成，从而复用登录后的 cookie 和会话状态。

b) 批量爬取 SKU 列表（搜索页）

- 代码实现：search_skus(keyword, pages=5) 函数
- 通过 input("搜索关键字：") 获取用户输入的搜索词。
- URL 构建：f"https://search.jd.com/Search?keyword={kw}&enc=utf-8&page={p*2-1}&log_id={time.time()}"，这里 kw 是 URL 编码后的关键词 (quote_plus(keyword) 在主程序部分完成)，p*2-1 体现了京东搜索页奇数页翻页的逻辑。
- 使用 requests.get() 获取搜索页 HTML。
- SKU 提取：主要通过正则表达式 PATTERN = re.compile(r'data-sku="(\d{6,})"') 从 <li class="gl-item" data-sku="..."> 标签中提取。同时，代码中还有一处兜底逻辑 m = re.search(r'"skuIds"\:("[\d,]+")', html)，尝试从页面 <script> 可能存在的 JSON 结构中提取 skuIds。

c) 逐 SKU 打开商品页 → 点击 商品评价 → 监听 Ajax * 代码实现：driver_get_data(tab, sku) 函数。

- 打开商品页：url=f'https://item.jd.com/{sku}.html', tab.get(url, retry=5, interval=3)。
- **获取价格**：selector = f'css:.price.J-p-{sku}', price_text = tab.ele(selector).text.strip()。这里使用了包含 SKU 的特定 CSS 选择器。
- **滚动触发懒加载**：drop_down(tab) 函数通过循环执行 tab.run_js(f'document.documentElement.scrollTop={init_count}') 实现页面向下滚动约 $13 * 300 = 3900$ 像素，以确保评论区加载。
- **监听 Ajax**：tab.listen.start('https://api.m.jd.com/?appid=item-v3&functionId=pc_club_productPageComments&client=pc') 和 tab.listen.set_targets(...) 精确设置了需要捕获的评论 API 接口 URL。
- **触发评论加载**：tab.ele('text:商品评价').click(by_js=True) 点击“商品评价”选项卡。

d) **解析 JSON → 写 CSV** * 代码实现：在 driver_get_data 中，通过 for pkt in tab.listen.steps(): 遍历捕获到的数据包。

- jd = pkt.response.body 获取 JSON 响应体。
- 遍历 jd['comments'] 列表，提取 guid(作为用户标识)、userProvince(评论 IP)、productColor, productSize, creationTime, score, usefulVoteCount, content, images(判断是否有图评论)等。
- **写入 CSV**：使用全局的 csv_writer 对象将提取的数据写入 CSV 文件。表头在主程序部分定义，实际写入时，'是否是图片评论' 通过 1 if c.get('images') else 0 判断。

e) **防封策略**：随机 sleep、翻页节流、复用同一浏览器实例

- ✓ 随机 sleep：在 search_skus、drop_down 和 driver_get_data 中均有不同时长的 time.sleep()调用。
- ✓ 翻页节流：search_skus 中每页请求后都有 sleep。
- ✓ 复用同一浏览器实例：整个脚本执行过程中，Chromium 实例 browser 及其标签页 tab1 被复用。
- ✓ 请求头：HEADERS 变量中定义了 User-Agent 和 Cookie（Cookie 为空，依赖登录后浏览器自带）。

2.2.2 登录与浏览器初始化

核心目的：通过用户手动操作一次登录，使后续爬虫能利用已登录的 cookie 访问京东数据，从而绕过登录验证和验证码。

代码流程概览：

a) **配置浏览器选项** (ChromiumOptions):

- 指定本地浏览器路径（如代码中所示的 Edge 浏览器）。
- 默认以**有头模式**（显示界面）运行，便于用户手动登录。

```
co = ChromiumOptions()  
# path = r'C:\Program Files (x86)\Microsoft\Edge\Application\msedge.exe' # 用户代码中指定的路径  
# co.set_browser_path(path)
```

b) 启动浏览器并获取标签页:

- 使用配置好的选项 co 启动 Chromium 浏览器实例。
- 获取浏览器当前最新的标签页 tab1，后续操作将在此标签页进行。

```
browser = Chromium(co)  
tab1 = browser.latest_tab
```

c) 引导手动登录 (driver_login 函数):

- 脚本调用 driver_login(tab1, 'https://passport.jd.com/uc/login')。
- 函数内部，tab.get() 打开京东登录页。
- input('请手动登录后按回车继续...') 会暂停脚本，提示用户在浏览器界面完成登录操作（如扫码）。
- 用户登录成功后，浏览器会自动管理 cookie。用户按回车，脚本继续执行，后续请求将携带有效的登录凭证。

d) 关键点:

- ✓ **一次性手动介入**：脚本启动时，用户只需登录一次。
- ✓ **会话复用**：脚本在运行期间，会持续使用当前浏览器实例的登录状态。
- ✓ **自动化潜力**：通过保存和加载 cookie 文件，可以进一步减少手动操作，提升自动化程度。

2.2.3 搜索页抓 SKU: search_skus()

该函数的核心职责是根据用户提供的关键词，从京东商城的搜索结果页面中收集一系列唯一的商品编码（SKU）。

a) **关键词 URL 编码**: 用户输入的关键词会通过 quote_plus(keyword) 进行 URL 编码。这个步骤是在 if __name__ == '__main__': 主代码块中调用 search_skus 函数之前完成的。这样做可以确保关键词中的特殊字符（如空格、中文字符等）被正确转换为 URL 格式，以便 HTTP GET 请求能够正确执行。

```
# 主代码块中的实现：  
keyword = input("搜索关键字: ")  
kw_encoded = quote_plus(keyword) # 编码后的关键词传递给 search_skus
```

b) **抓取奇数页**: 代码会遍历用户期望搜索的页面数量（由 `search_skus` 函数的 `pages` 参数控制，默认为 5 页）。每个搜索结果页的 URL 构造方式如下：

```
# search_skus 函数内部:
url = (f"https://search.jd.com/Search?keyword={kw}&enc=utf-8"
      f"&page={p*2-1}&log_id={time.time()}")
```

其中 `p*2-1` 的部分准确地实现了京东分页的逻辑，即使用奇数页码（1, 3, 5, ...）。

c) **正则抽取**:

- **主要提取方式**: 一个全局定义的正则表达式 `PATTERN = re.compile(r'data-sku=(\d{6,})')` 被用来从页面 HTML 中提取 SKU。在 `search_skus` 函数内部，通过 `requests.get(url, headers=HEADERS, timeout=10).text` 获取页面 HTML 文本后，使用以下代码进行 SKU 提取：

```
python      # search_skus 函数内部:      sku_all.update(PATTERN.findall(html))
```

这会查找所有 `data-sku="<SKU_ID>"` 格式的字符串。`(\d{6,})` 部分会捕获长度至少为 6 位的数字作为 SKU ID。

- **备用（兜底）提取方式**: 为了应对 SKU 可能以不同方式嵌入 HTML（例如，由于 A/B 测试导致 SKU 存在于 `<script>` 标签内）的情况，代码中包含了一个备用提取逻辑：

```
# search_skus 函数内部:
m = re.search(r'"skuIds":\s*"([\d,]+)"', html)
if m:
    sku_all.update(m.group(1).split(","))
```

这个正则表达式会查找类似 `"skuIds": "123,456,789"` 这样的模式，如果找到，则会提取并分割这个由逗号分隔的 SKU 字符串，然后将这些 SKU 添加到 `sku_all` 集合中。

d) **随机** `sleep(random.uniform(1, 2))`: 在处理完每一页并提取完 SKU 后，代码会执行一个随机延时：

```
# search_skus 函数内部:
time.sleep(random.uniform(1, 2))
```

这个 1 到 2 秒的暂停是一个关键的反爬虫限速措施，用以防止脚本因请求过于频繁而被京东服务器阻止。

e) **去重与返回**: sku_all 变量（在京东评论.py 的 search_skus 函数中，它是一个在函数内部初始化的局部 set 集合：sku_all = set()）用于存储所有提取到的 SKU。使用 set 数据结构可以自动处理重复的 SKU，确保每个 SKU 的唯一性。函数最后返回一个包含所有不重复 SKU 的列表。

```
# 京东评论.py 中 search_skus 函数的实际结构：
def search_skus(keyword, pages=5): # keyword (kw) 在传入时已被编码
    sku_all = set() # 函数局部集合，用于存储当前函数调用提取的SKU
    # ... (构建URL和执行 requests.get) ...
    # ... (使用 PATTERN.findall(html) 提取并更新 sku_all) ...
    # ... (使用 re.search 查找 skuIds 并更新 sku_all) ...
    # ... (执行 time.sleep) ...
    return list(sku_all) # 返回去重后的SKU列表

# 主代码块中调用：
# all_sku_list = search_skus(kw_encoded, pages=PAGES_TO_SEARCH)
```

f) **坑点处理**: 处理了 SKU 可能存在于 <script> 标签内的“坑点”。以下代码段：

```
m = re.search(r'"skuIds":' + '([\\d,]+)' + "'", html)
if m:
    sku_all.update(m.group(1).split(","))
```

专门查找并提取形如 "skuIds": "123,456,789" 模式中的 SKU。这表明在设计爬虫时充分考虑了京东页面结构可能存在的变化和 A/B 测试等情况。

2.2.4 商品页采集：driver_get_data()

a) 获取价格

```
url = f'https://item.jd.com/{sku}.html'
tab.get(url, retry=5, interval=3)
price = tab.ele(f'css:.price.J-p-{sku}').text.strip()
```

retry=5 抵御 502/504；interval=3 限制连击

b) 滚动触发加载

```
for i in range(13):
    tab.run_js(f'document.documentElement.scrollTop={i*300}')
    time.sleep(random.uniform(0.3, 0.6))
```

- $13 \times 300 \text{ px} \approx 4000 \text{ px}$ ，恰到评论区
- 更快做法：element.scrollIntoView() 直接定位

c) 监听 Ajax 抓评论包

```
LISTEN_URL = (  
    'https://api.m.jd.com/?appid=item-v3&'  
    'functionId=pc_club_productPageComments&client=pc'  
)  
tab.listen.start(LISTEN_URL)  
tab.ele('text:商品评价').click(by_js=True)
```

- 接口返回 JSON, DrissionPage.listen 可实时抓响应体
- 点击 商品评价 即触发第 1 页请求

d) 解析 JSON → 写 CSV

```
for pkt in tab.listen.steps():  
    jd = pkt.response.body  
    for c in jd['comments']:  
        csv_writer.writerow([  
            sku, price,  
            c['nickname'],  
            c['productColor'],  
            c['score'],  
            c['content'],  
            int(c['imageCount'] > 0)  
        ])
```

- 仅保留 7 列关键字段
- imageCount 转 0/1 → 后续可做“有图率”指标
- 全程同一个 csv_writer, 比 pandas.to_csv(..., mode="a") 更快

2.2.5 异常处理与人工兜底

```
new_tab = browser.latest_tab  
if new_tab != tab:          # 极少数商品页评论在新标签  
    new_tab.close()  
    input("manual fix")      # 人工干预
```

- 京东偶尔弹新标签; 脚本发现后先关, 再请人工确认
- 生产环境可自动切换标签或超时回退, 避免卡死

2.2.6 可改进方向

问题	影响	建议
手动登录	无法无人值守	将 cookie dump 成 cookies.json，下次复用
单线程 SKU 处理	1000+ SKU 耗时长	asyncio.gather() + 3-5 个浏览器实例并发
全局 count 变量	多线程不安全	用 multiprocessing.Value 或直接读文件行数
监听 URL 写死	京东可能改 functionId	用正则匹配片段 pc_club_productPageComments
input() 卡流程	无人值守会阻塞	try/except TimeoutError 超时自动 continue

爬虫架构小结

整体思路为“**搜索页正则拿 SKU** → **商品页 Ajax 抓评论** → **CSV 落盘**”：该方案首先利用 requests 库结合**正则表达式**高效抓取京东搜索页中的商品 SKU 列表，这一步避免了驱动浏览器加载整个搜索页，效率较高，并设计了备用正则逻辑以应对页面结构变化。随后，利用 DrissionPage **驱动无头浏览器**（如 Chromium）访问各个 SKU 对应的商品详情页。在商品页，通过**模拟滚动**确保评论区加载，并核心利用 DrissionPage 的**网络监听功能**，**精准捕获**加载评论数据的特定 Ajax 接口（pc_club_productPageComments）所返回的 JSON 数据包。最后，**实时解析 JSON**，提取所需字段（如评论内容、IP、时间、评分等），并利用 CSV 模块**追加写入本地 CSV 文件**，实现数据持久化。

优点：

- **依赖少、抗界面改版**：混合模式（requests + DrissionPage）减少了对浏览器自动化的全程依赖，且核心评论抓取依赖于相对稳定的 Ajax 接口而非易变的 HTML 元素，因此对前端页面的改版有较好的抵抗力。
- **精准高效**：DrissionPage 的 Ajax 监听功能能够直接获取底层数据，避免了复杂的页面元素定位与解析，**速度快**且数据完整性高。
- **技术栈清晰**：DrissionPage 结合了 requests 的便捷性和浏览器驱动的动态处理能力，流程相对明确。

缺点：

- **登录依赖人工**：当前版本需要**用户手动扫码登录**以获取访问评论接口所需的 cookie 和会话状态，这使得爬虫**无法实现完全无人值守**。
- **SKU 串行速度有限**：获取到 SKU 列表后，**逐个访问商品页并抓取评论**是串行执行的，当 SKU 数量庞大时，整体耗时长。
- **鲁棒性待提升**：**异常处理机制较为基础**，且监听的 Ajax URL 为固定字符串，若京东接口变更可能导致爬虫失效。

2.3 数据处理与可视化

2.3.1 脚本概览与任务调度

visualization.py 脚本是数据分析与可视化的执行核心，它将爬取到的评论数据（默认为总评论 final.xlsx）转化为一系列图表和分析结果，旨在揭示不同城市的“消费性格”。

2.3.2 依赖与全局设置

- **数据科学三件套**：pandas / numpy / matplotlib
 - **可视化增强**：seaborn / plotly.express / plotly.graph_objects
 - **文本分析**：jieba / gensim / wordcloud / snownlp
 - **机器学习**：sklearn.GaussianMixture
 - **地理数据**：geopandas
-

2.3.3 数据读取与清洗 load_data()

1. 读取 Excel「总评论 final.xlsx」。
2. 尝试把「评论时间」列转换为 datetime。
3. 确保 **评论 IP** 与 **价格** 两列存在，否则抛异常。

```
df = pd.read_excel(xlsx)
df["评论时间"] = pd.to_datetime(df[time_cols[0]])
for col in ["评论IP", "价格"]:
    if col not in df.columns: raise KeyError
```


2.3.4 省级地图热力图

1) 省级评论量热力图 heatmap_city_activity()

- 统计每省评论条数后，与中国省级 GeoJSON 合并。
- 取 90% 分位截断极端值，再绘制渐变色块图。
- 输出 PNG：heatmap_city_activity.png

```
cnt = df["评论IP"].value_counts().reset_index()
gdf = gpd.read_file(geojson).merge(cnt, left_on="name",
                                     right_on="province", how="left")
gdf.plot(column="cnt", cmap="Reds", legend=True)
plt.savefig("heatmap_city_activity.png", dpi=300)
```

省级评论量热力图



深度解读

数据描述 → 空间分布特征 → 可能驱动因素


1. 描述性统计

指标	数值
总评论数	53 934
覆盖省级行政区	36 个（含“未知”）
平均每省评论数	1 498 条
中位数	1 359 条
90% 分位数（截断上限）	2 022 条

2. 空间分布特征（Top 10）

排名	省份	评论数	占全国比重
1	广东	3 512	6.5 %
2	江苏	2 503	4.6 %
3	未知	2 203	4.1 %
4	北京	2 111	3.9 %
5	山东	1 933	3.6 %
6	河南	1 811	3.4 %
7	浙江	1 794	3.3 %
8	上海	1 717	3.2 %
9	四川	1 715	3.2 %
10	河北	1 619	3.0 %

城市等级分布图（按评论数量）



用户地理分布概览：评论数量 Top 15 城市

通过绘制去除“未知”IP 的南丁格尔玫瑰图，我们可以更加直观地看到各核心区域的评论体量分布。

- **头部集中度**：前 5 省份贡献 $\approx 22.7\%$ ，前 10 省份贡献 $\approx 38.8\%$ 。尾部 10 省份仅占 $\approx 11\%$ ，存在明显的“长尾”现象。
- **沿海 + 一线城市**：珠三角、长三角、京津冀在榜单中占据主导，符合电商渗透率与经济活跃度高的预期。

- **人口大省支撑**：河南、四川虽经济水平中等，但人口基数大，拉升了总评论量。
- **数据漏斗**：“未知”占 4.1%——因京东评论数据结构限制，有些评论没有“评论 IP”一项，且前期爬虫过程忽略此漏洞，最终版爬虫代码已改正，确保有“评论 IP”一项。

3. 可能驱动因素与验证思路

维度	解释假设	数据验证方式
人口规模	人多评论多	用人口普查数据计算评论密度(条/万人)
经济活跃度	GDP/人均收入高 → 线上消费多	与省级 GDP 做皮尔逊/斯皮尔曼相关
互联网普及率	上网率高 → 评价多	引入 CNNIC 报告的省级上网率

a) 省级评论驱动因素分析 `analyze_comment_drivers()`

该函数在 `visualization.py` 中新增，实现以下流水线：

步骤	逻辑	关键代码
1	读取 <code>province_stats.csv</code> ，验证列 <code>province / population / gdp / internet_rate</code> 完整	<code>stats_df = pd.read_csv(...)</code>
2	调用 <code>_norm_name()</code> 统一省份名称，处理空值与后缀	<code>stats_df["province"] = stats_df["province"].apply(_norm_name)</code>
3	过滤原始评论表中 评论IP ≠ "未知" 的记录，统计各省评论量	<code>.value_counts().reset_index()</code>
4	与统计表 <code>merge</code> ，得到人口、GDP、网普率、评论量合表	<code>stats_df.merge(cnt, on="province")</code>
5	计算 评论密度 <code>comment_cnt / (population / 1e4)</code>	<code>merged["comment_density_per10k"] = ...</code>
6	计算评论量与 GDP、互联网普及率 的 Pearson / Spearman 相关系数	<code>merged[["comment_cnt", "gdp"]].corr(...)</code>
7	保存指标表 <code>comment_driver_metrics.csv</code> ，并输出两张散点图	<code>plt.savefig(...)</code>

通过该流程，可快速评估宏观经济与网络基础对线上互动活跃度的影响。


b) 相关性结果 · 本次运行

Pearson (评论量 ~ GDP)	0.905
Spearman (评论量 ~ GDP)	0.911
Pearson (评论量 ~ 互联网普及率)	0.666
Spearman (评论量 ~ 互联网普及率)	0.743

GDP 与评论量高度正相关（皮尔逊 ≈ 0.91 ，斯皮尔曼 ≈ 0.91 ），说明经济体量越大、线上消费越活跃。

互联网普及率相关性中等（皮尔逊 ≈ 0.67 ），在控制人口后仍呈正向，但影响不及 GDP 显著。

c) 结果可视化



点群大致沿对角线向右上分布,GDP 超过 9000 亿元的省份(如广东、江苏)同时也是评论量最高的头部区域。

在 65%-88%区间呈 上抛物线;当网普率 $\geq 80\%$ 后评论量增幅更明显,但仍受 GDP 与人口规模共同制约。

综上，GDP 是当前数据里 **更强的解释变量**，互联网普及率则是 必要非充分条件：网速覆盖到位后，消费能力才真正转化为活跃交互行为。

d) 进一步分析

从我们之前的分析中可以看出，**GDP** 与评论量的高度相关性显示出 **经济活跃度对在线互动的推动作用**。而 **互联网普及率** 的中等相关性则表明，**基础设施的完善**是推动用户评论行为的必要条件，但并非唯一因素。

1. GDP 和评论量的正相关：

这表明大多数高 GDP 省份拥有更多的消费能力，进而有更高的评论量。这不仅仅是由于经济活动的增加，也可能与 **电子商务渗透率** 和 **物流配送效率** 密切相关。消费者在更高经济水平的地区，可能有更多的在线购物需求，导致更多的评价行为。

2. 互联网普及率和评论量的正相关：

互联网普及率高的省份更可能促进线上互动，但这并不意味着网络基础设施完善就能直接增加评论量。比如，互联网普及率较高的省份（如北京、上海）并不一定是评论量最多的省份。实际情况可能是 **经济活动和消费行为的交织作用** 更为重要。在 **互联网普及率 $\geq 80\%$** 的省份，评论量有明显的增加，这表明，互联网普及是**潜力的释放器**，但 **经济因素** 仍然是 **核心驱动力**。


2) 省级情感得分热力图


sentiment_metrics_by_province 函数：计算省级情感指标，此函数的核心目标是计算并汇总各省份基于评论内容的情感指标。

输入数据：

- `geojson_path`：一个指向 GeoJSON 文件的路径，该文件用于后续的省份名称校验。
- `out_csv`：输出的 CSV 文件名，默认为 `"province_sentiment_metrics.csv"`。
- `positive_th`：一个浮点数值阈值，默认为 `0.8`，用于判断一条评论是否属于“正面评论”。


主要处理流程：






heatmap_sentiment_spikes 函数：可视化省级情感得分热力图与柱形标注

此函数的核心目标是将各省份的情感得分数据可视化为一张带有柱形标注的中国地图热力图。






代码综合功能总结

代码首先处理原始评论数据，计算出各省的情感统计指标并保存；然后利用这些指标和地理空间数据，生成一张结合了区域颜色渲染和重点区域柱形强调的可视化地图。

省级平均情感分热力图（含柱形标注）



可视化结论：色块→柱子→地理

1. 维度：色块（底图）

主要观察：色阶被人为限定在 0.73–0.86 相对积极的区间进行差异化着色

- 深绿（得分较高，约 0.83-0.86）：江苏、浙江、山东、北京及周边（如天津、辽宁部分）、黑龙江。
- 浅绿/黄（得分中等，约 0.78-0.82）：中部大部分省份、东北部分地区。
- 橙/红（得分较低，约 0.73-0.77）：广东最红（得分最低），其次为海南、广西、新疆、青海、西藏等。

区域情感差异解读：东高、粤低、西挑战

评论情感得分呈现显著的区域分异，反映了不同地区消费环境与用户心态的差异

东部沿海及环渤海（高分区域 - 除广东）：平均情感最为正向。得益于成熟的电商环境、高效的物流体系以及用户对主流产品/服务较高的熟悉度与满意度。

广东（低分特殊区）：作为经济发达和订单大区，情感得分却垫底。可能因为用户见多识广，对品质、服务和性价比的期望更高，因此更挑剔；市场透明，货比三家容易，负面信息易得，评价更审慎/批判；评论可能集中于特定活动、品类或售后环节，天然拉低平均分。

西部地区（低分挑战区 - 新疆、西藏、青海等）：情感得分偏低。因面临物流覆盖与时效、商品丰富度、售后服务可达性等客观挑战，也可能与当地线上消费习惯与表达方式有关。

结论：评论情感不仅反映产品本身，更是区域消费生态（基建、竞争、用户成熟度）的综合体现。广东的“低分”尤其值得关注，它揭示了发达市场用户的高标准与复杂心态。

2. 维度：柱子（高度 $\propto (\text{score} - 0.7)^2$ ）

主要观察

- 最高柱（得分显著高于 0.7 基线且被放大）：江苏、浙江、山东、辽宁、黑龙江、北京、上海等。
- 矮柱（得分接近 0.7 基线或略高）：广东、海南、西藏、新疆、广西等。

解读：差异放大效应，柱子高度设计（得分减去 0.7 后平方再乘以放大系数）的目的是为了在视觉上凸显高分省份。原始平均分差异可能仅在 0.1 左右（例如 0.75 vs 0.85），但经过平方和系数放大后，视觉差异被显著拉开。这意味着高柱地区的实际情感均分可能在 0.84–0.86 区间，而矮柱地区则在 0.74–0.76 区间徘徊。“尖子生”效应，这种展示方式使得得分头部省份的“优秀”程度被进一

步强调，更容易吸引眼球，但也可能使得观者忽略中等表现省份的实际情况，或夸大头部与尾部的真实差距。**基线依赖**，0.7 作为基线是关键。如果大部分省份得分都远高于 0.7，则此基线能有效区分优等生；如果大部分省份得分在 0.7 附近，则柱子高度差异可能不明显或意义减弱。

3. 维度：地理梯度

主要观察：整体呈现“东高西低、北略高于南（广东除外）”的趋势，但广东是其中最显著的反常点。

解读：普遍趋势与个体差异：经济发展水平、物流基础设施、互联网普及率、民众整体受教育程度等宏观因素可能共同塑造了“东高西低”的整体情感格局。然而，这并不能解释所有情况。**广东再探讨：**广东的“反常”提示我们，区域经

方法与局限

1. SnowNLP 打分：便捷性与潜在偏差

SnowNLP 作为通用中文情感分析工具，可能对于特定行业、特定场景、特定口语化或网络用语的理解不够精准，导致情感判断出现偏差（例如，用户可能用反讽、抱怨的语气表达中性或轻微不满，但模型仍判断为中性或略正）。观察到情感分在 0.7-0.9 之间聚堆，可能意味着 SnowNLP 本身对文本的积极倾向判断略高，或者评论数据本身正面内容就较多，且模型难以拉开细微的积极程度差异。

2. 柱高 $(s-0.7)2timesk$ ：视觉冲击与量化解读

平方项使得高分区域的优势被不成比例地放大，虽然视觉冲击力强，但牺牲了对真实数值差异的直观感知。用户可能难以从柱高直接推断实际情感分差距。柱子的高度单位（经过平方和乘数变换后）与原始情感分（0-1 范围）不再直接对应，缺乏直观的业务含义。

2.3.5 省级会员渗透蜂窝图

代码生成一个蜂窝状的螺旋图，其中每个六边形代表一个省份，其颜色和在螺旋中的位置由指定列（默认为会员占比 `member_pct`）的值决定。值越高的省份越靠近中心。

a) 代码主要组成部分


1. 辅助函数：生成六边形网格坐标

目的：建立六边形在 **轴向坐标系** (q, r) 中的逻辑位置。


- `ring_coords(k)`: 计算并返回距离中心点 k 个单位 **环** 上所有六边形的 (q, r) 坐标。
- `concentric_coords(n)`: **由内而外** 依次调用 `ring_coords`，生成 n 个六边形的轴向坐标，确保坐标数量与数据点数量一致。

2. 主绘图函数: `member_hex_spiral`

- **目的**: 整合数据处理、坐标计算和可视化绘图。
- **输入**: 一个 Pandas DataFrame、一个用于排序和着色的列名 (`value_col`)、以及输出图片文件名。
- **关键步骤**:



b) 会员渗透蜂窝图



会员评论占比观察：核心发现

总体趋势： 会员评论占比呈现显著的“中心-外围”递减模式，反映了中国不同区域城市消费结构的成熟度、数字化水平及会员经济接受度的差异。

核心圈层解读：

位置	解读
第1圈 (中心 - 北京 56%)	全国最高。首都效应显著，消费者高收入、高学历、高数字化，追求品质、个性化与品牌价值，会员制契合度高。
第2圈 (沪苏浙鲁川冀 46%-50%)	沪苏浙鲁：东部发达省市，消费结构成熟，购买力强，会员接受度高，追求性价比与优质服务。 四川 (成都) ：新一线代表，消费年轻化、体验化，对新模式认同度高。 河北 ：受京津辐射，消费升级与电商渗透加快。
第3圈 (津鄂陕粤渝豫辽 42%-45%)	区域中心城市，消费快速升级，中产壮大，对会员价值认可度提升。 广东 (异常点 44%) ：占比相对偏低。可能原因：省内差异大、务实消费文化（重性价比）、B2C转型差异、平台/权益契合度问题。
第4-5圈 (其他省份)	占比偏低。原因：可支配收入相对较低、电商与物流待完善、消费侧重基本需求。 特殊地区 ：海南（旅游影响）、台湾/港澳（市场环境独特）。

配色印证： 图表颜色梯度直观展示了从中心高占比到外围低占比的趋势。

基于“圈层省份（会员评论占比）观察”信息，我们可以分析出以下几种典型的**城市消费性格**：

第一圈 (北京 - 成熟引领型)： 作为首都，拥有高收入、高学历与高度数字化的消费者。他们对**服务品质、个性化体验和品牌价值有极高要求**，不仅是高消费者，更是**积极互动、乐于表达意见**的深度参与者，引领着服务与升级型消费潮流。

第二圈 (沪苏浙鲁、川、冀 - 发达追随/新锐体验型)： 东部沿海地区（沪苏浙鲁）**购买力强、电商习惯成熟**，紧随北京追求品质生活，对会员价值（价格/服务/便捷）有明确期望。四川则代表新一线城市，**年轻、时尚、注重体验**，对新兴消费模式认同度高。河北则处于**受辐射带动和自身提升驱动的快速转型期**。

第三圈 (津鄂陕粤等 - 快速升级/潜力务实型)： 这些区域中心城市正经历**消费结构的快速升级**，中产阶层壮大，对品牌和服务的要求日益提高，开始认可会员价值。但广东作为**特殊案例**，因其**内部差异巨大、务实消费文化（重性价比）、市场竞争激烈**等因素，呈现出高度复杂、潜力巨大但平均会员渗透率相对较低的消费性格。

第四、五圈 (闽黑琼等 - 基础成长/特殊环境型)： 受限于相对较低的收入水平和待完善的电商基础设施，这些地区的消费**更侧重于满足基本生活需求**，对附加

会员服务的付费意愿和使用频率较低，代表了未来的潜力市场。海南（旅游）、台港澳（独特市场）等则受**特殊环境因素**显著影响，需区别看待。

总结:

从会员评论占比这一指标来看，中国的城市消费性格呈现出明显的**梯度特征**：

- **核心城市 (北京/上海)**: 成熟、高标准、数字原生、价值导向。
- **发达区域/新一线**: 紧随其后，追求品质/体验，但各有侧重。
- **区域中心**: 处于快速升级通道，潜力巨大，但可能伴随务实或多元的特性（如广东）。
- **发展中区域**: 更侧重基础，消费潜力待挖掘，或受特殊因素主导。

这种差异性，深刻体现了不同地区的多样性消费性格。

2.3.6 岗位数 × 评论量气泡图

a) scatter_jobs_vs_comments()函数分析

此函数用于生成一个气泡图，对比各省份的岗位数量和评论数量，气泡的大小则代表该省份的平均薪资。该函数会输出一个交互式的 HTML 文件和一个静态的 PNG 图片文件。

➤ 数据源:

df (传入的 DataFrame): 包含 '评论 IP' 列，用于统计各省评论数。job_cnt.csv (外部文件): 包含各省份的岗位数 (job_cnt) 和平均工资 (avg_salary)，其中省份列应为 province。

➤ 处理逻辑:

检查 job_cnt.csv 文件是否存在，若不存在则跳过。读取岗位数据。统计主 DataFrame df 中各省份 ('评论 IP') 的评论量 (comment_cnt)。将评论量数据与岗位数据按省份 (province) 内连接 (inner merge) 合并。

使用 plotly.express.scatter 创建气泡图: x 轴: job_cnt (岗位数), y 轴: comment_cnt (评论量), 气泡大小: avg_salary (平均薪资), 颜色: province (各省份不同颜色), 悬停数据包含平均薪资等。


➤ 输出:

交互式 HTML: scatter_jobs_vs_comments.html, **静态图片**

PNG: scatter_jobs_vs_comments.png (需安装 kaleido 包)

```
# 核心绘图逻辑示意（假设 comm 和 job DataFrame 已准备好且均有 'province' 列）
# comm: [province, comment_cnt]
# job: [province, job_cnt, avg_salary]
g = pd.merge(comm, job, on="province", how="inner") # 使用 pd.merge 更通用
fig = px.scatter(g, x="job_cnt", y="comment_cnt",
                 size="avg_salary", color="province",
                 hover_name="province",
                 title="岗位数 vs 评论量")
fig.write_html("scatter_jobs_vs_comments.html")
# fig.write_image("scatter_jobs_vs_comments.png") # 取消注释以保存PNG
```

b) 交互式气泡图预览（附件 html 为可交互）



气泡图解读

该气泡图通过对比各省份的“岗位数”（横轴）、“评论量”（纵轴）以及“平均薪资”（气泡大小），为我们提供了一个多维度审视区域经济活力与数字消费活跃度的窗口。结合城市消费结构理论，我们可以从图中解读出以下关键信息：

1. 总体趋势观察：

岗位数与评论量之间**无简单线性关系**。平均薪资和**城市消费结构**是关键影响因素，解释了为何高评论量可出现在高岗位（广东）或低岗位（北京）地区。

2. 主要省份集群与消费结构推演：

集群	特征	解读
高数字参与 + 高经济活力型 (广东、江苏)	评论量高、岗位数高、薪资较好。	消费能力强，电商渗透高，线上互动活跃，消费多元化。
超大城市引领型 (北京、上海)	评论量极高、岗位数(图中口径)低、薪资最高。	服务业主导，高购买力，追求品质、服务与体验，数字消费发达。
产业驱动型 (如湖南/福建等)	岗位数最高、评论量中等、薪资中等。	实体产业主导，就业多，但线上参与度或薪资水平限制了评论量，可能偏向实物消费。
成长型区域中心 (山东、浙江、川鄂等)	岗位与评论量居中，薪资多样。	快速城市化与消费升级，潜力巨大，市场充满活力。
待开发潜力区 (左下角省份)	岗位与评论量均低。	消费以基本需求为主，需提升收入、完善数字基建。

3. 平均薪资的调节作用：

高薪资能显著提升购买力和线上参与意愿（如北京、上海），驱动高价值消费。薪资是衡量**消费升级潜力**的重要指标。

4. 对城市消费结构研究的启示：

- **多指标评估**: 需结合岗位、薪资、评论量等综合判断消费结构。
- **评论量是“数字活力镜”**: 反映线上活跃度和数字经济接纳度。
- **区域差异化策略**:
 - ✓ **京沪**: 推高附加值服务与体验。
 - ✓ **粤苏**: 强化品牌与用户互动。
 - ✓ **鲁浙川等**: 抓消费升级，推品质性价比产品。
 - ✓ **产业驱动区**: 挖掘细分市场需求。

结论： 该图揭示了各地区经济活力、购买力与数字消费文化间的关联，不同消费结构造就多样性消费性格。

2.3.7 R-F-M 价值矩阵

a) rfm_heatmap()函数分析


此函数旨在对省级评论数据进行 RFM 分析，并产出两个核心结果：

成果	目的	坐标	内容
RFM 热力图 (province_rfm_heatmap.png)	可视化不同 RF 分群的 平均客单价 (M 值)	R (近 30 天评论量) 为 X 轴 F (累计评论量) 为 Y 轴	单元格数值和颜色代表对应 RF 分群下省份的 平均客单价
RF 分群省份列表 (RF_province_list.xlsx)	清晰展示每个 RF 组合具体包含了哪些省份	无	一个表格，行列为 RF 分数，单元格内为对应的省份名称列表

主要处理步骤：

- **数据清洗**: 标准化省份名称（去“省/市”、去无效值）和评论时间。
- **RFM 原始值计算**: **R**: 计算各省近 30 天评论数。**F**: 计算各省累计评论数。**M**: 计算各省平均客单价。
- **RFM 分箱打分**: 使用 pd.qcut 将 R, F, M 原始值分别划分为 3 个等级 (1, 2, 3)。
- **透视与可视化**: 创建数据透视表，以 R、F 为轴，M 值为内容，用 seaborn.heatmap 绘制并保存热力图。
- **分组与输出**: 按 RF 分数组合，提取省份列表，打印并保存为 Excel 文件。

b) RFM 热力图分析



F	R=1	R=2	R=3
1	云南, 台湾, 宁夏, 海南, 港澳, 甘肃, 美国, 西藏, 贵州, 青海	内蒙古, 新疆, 黑龙江	
2	山西, 辽宁	吉林, 天津, 广西, 湖南, 重庆, 陕西	安徽, 江西
3		福建	上海, 北京, 四川, 山东, 广东, 江苏, 河北, 河南, 浙江, 湖北

模型解读:

1. 核心分群解读 (结合平均客单价 M 值):

核心分群	行为	解读
F3R3 (高频高价核心区 - 京沪粤苏浙川等, M=474 元)	时尚引领者, 购买力强, 高频、高价、线上主流。	成熟市场, 追求品质、品牌与潮流。
F1R1 & F1R2 (低频超高价潜力区 - 云南、新疆等, M=504-515 元)	评论少但客单价最高。	“隐形富豪”或特殊需求驱动 (大宗采购、高档/功能性服装、跨境/旅游)。
F2R3 & F3R2 (成长与唤醒腰部区 - 皖赣、福建, M=458-476 元)	F2R3 近期活跃度高, F3R2 历史基础好但近期一般, 客单价均较高。	F2R3 是重要增量市场; F3R2 是需激活的熟客。
F2R1 & F2R2 (稳定高价值中坚区 - 晋辽津湘渝等, M=486-487 元)	历史评论中等, 客单价高, 但近期活跃度一般或偏低。	具备消费能力, 可能偏向计划性、品质型购买, 需激

2. 核心洞察:

普遍高客单价: 表明平台主要吸引具有一定购买力、追求品质的服装消费者。

3. 消费性格分析:

F3R3	这部分消费者是市场的 意见领袖和高频贡献者 。他们对时尚潮流敏感, 品牌意识强, 愿意且能够为高品质、高设计的服装持续付费。他们 既追求“新”也追求“质” , 是品牌最希望拥有的核心用户群。
F1R1/F1R2	这部分消费者展现出 “不鸣则已, 一鸣惊人” 的性格。他们可能不常购买, 但一旦出手, 目标明确, 追求高价值或特定功能/场合的服装。他们的 消费行为更理性、目的性强 , 可能是为换季、特殊场合或特定需求 (如户外、保暖) 进行集中采购, 是高客单价的“潜力股”。
F2R3/F3R2	展现出 积极向上、乐于尝试 的性格, 是 新兴的活跃力量 , 对时尚

和线上购物接受度高，代表了市场的**增量潜力**。F3R2 群体则像是“**曾经的爱人**”，他们有**消费基础和能力**，但近期活跃度下降，可能需要新的刺激或理由来重新点燃热情，性格上属于**有基础但需唤醒**的类型。

F2R1/F2R2

这部分消费者是市场的**中坚力量**，性格上可能**更为稳重和务实**。他们拥有不错的消费能力，但消费行为可能更**偏向计划性、注重品质与耐用性**，而非盲目追赶潮流。他们是**可靠但需要激励**的群体，提升其活跃度是关键。


4. 主要局限性:

- ❖ 评论量 ≠ 实际购买。
- ❖ 省级数据掩盖城市差异。
- ❖ “服装”品类笼统。

总结: 通过 RFM 模型，我们不仅识别了不同区域的服装消费特征，更重要的是，我们描绘出了**四种典型的服装消费性格**：**追求前沿与高价值的“时尚引领核心型”**、**购买精准且高客单的“目标导向潜力型”**、**充满活力或待激活的“成长唤醒型”**，以及**注重品质与计划的“稳定价值驱动型”**。

2.3.8 省份-服装品类关联网络分析

在通过用户价值分层（如 RFM）对省份进行初步画像后，我们有必要进一步探究不同省份与具体服装品类之间的直接关联，以更细致地理解其**服装消费结构**的特点。网络图是一种直观展示多对多关联关系的有效工具。下图通过“Spring”力导向布局，呈现了核心省份与主要服装品类之间的连接网络。



网络图解读展示了省份与服装品类间的关联，揭示了以下关键消费结构特征：

核心区域 = 多元市场 (京沪粤鲁津渝等)	这些中心节点省份/城市是核心服装市场，需求覆盖广泛品类，具有主导影响力。
气候驱动消费	羽绒服是核心品类，与北京、山东等北方地区强关联，凸显保暖需求是重要结构因素。
生活/经济驱动消费	西装/衬衫与京沪紧密相连，反映商务着装需求。广东与T恤/短裤强关联（气候影响），也与礼服有关联（产业/文化影响）。
区域与品类偏好	省份连接线显示消费侧重（如广东偏休闲夏装，京鲁偏保暖商务）。图谱区分了普适品类（如羽绒服）与区域性/特定偏好品类。

结论：网络图直观地展现了地理、气候、经济和生活方式如何共同塑造了中国不同区域的服装消费结构。


2.3.9 城市-关键词 PCA 聚类分析


a) PCA 函数分析

目标：挖掘并可视化具有相似旅游评论特征的城市群组。

方法：主成分分析 (PCA) + K-Means 聚类。


步骤：





核心思想：通过简化数据维度并进行聚类，直观地识别出旅游评论关键词相似的城市群，以便进行后续分析。

b) PCA 聚类结果解读与后续研究重点



服装消费 PCA 聚类解读：识别关键市场

核心发现：

1. **PC1 主导差异：** 第一主成分 (PC1) 解释了 **78.54%** 的方差，是区分省份服装消费模式的**最关键维度**。
2. **两大集群：**

Cluster 1 (主流市场 - 含上海): 包含绝大多数省份，位于图左侧 (低 PC1)，代表了**共性强的主流消费模式**。

Cluster 2 (独特市场 - 含京粤): 少数省份，位于图右侧 (高 PC1)，**北京和广东**是其中最突出的极端点，代表了与主流**显著不同的消费模式**，可能更高端或独特。

!!! 为何后续调查重点研究京沪粤?

选择北京、上海、广东作为研究重点，是因为它们能构建一个“主流核心 vs. 独特极端”的对比框架：

北京 & 广东 (Cluster 2): 代表了**独特**的消费模式，是研究市场**多样性**的关键样本。

上海 (Cluster 1): 代表了**主流**市场中的**核心与标杆**，提供了理解主体特征和进行对比的**基准**。

结论： 通过研究这三个代表性地区，可以全面把握中国服装消费市场的**主体特征与显著差异**，为品牌和市场策略提供有力支持。

2.3.10 价格分位箱线图


a) boxplot_price_tier()函数分析

此函数 `boxplot_price_tier` 的主要目的是将评论数据按省份划分为四个特定的组（北京、上海、广东、及其他），然后针对这四个组绘制关于“价格”（或客单价）的箱线图，以便比较这些组在价格分布上的差异。

以下是代码的逐步分析：

步骤	目的	操作
1. 省份名称提取与标准化	统一提取评论用户的省份信息，便于后续分组。 将省份归类为	利用字符串处理，移除“省”与“市”，并去除空格，将结果保存到新列 <code>province</code> 。
2. 省份层级分组 (Tiering)	“Beijing”、 “Shanghai”、 “Guangdong” 和 “Other” 四个组别。	通过字典映射，将“北京”、“上海”、“广东”分别归入对应英文标签，其余省份为“Other”，结果存入新列 <code>tier</code> 。
3. 绘制箱线图	可视化不同层级省份的价格分布情况。	用 Seaborn 绘制以 <code>tier</code> 为分组、价格为数值的箱线图，指定显示顺序，添加标题和轴标签，并保存为 <code>box_price_tier_4groups.png</code> 。

b) 客单价箱线图分析



服装客单价箱线图解读：洞察地域消费力

目标： 通过比较北京、上海、广东及其他区域的服装客单价分布，揭示不同地域的消费结构特征。

地区	特征	解读
北京 (Beijing)	中位数高 (约 250-300 元)，常规消费范围广 (100-1200 元)， 高价异常点极多 。	消费结构多元 ，既有中档需求，更有 强劲的高端消费力 。
上海 (Shanghai)	中位数最高 (约 280-330 元)，常规范围与北京相似但略高， 高价异常点极多 。	时尚标杆 ，平均消费水平和高端购买力突出，对品牌、设计追求极致。
广东 (Guangdong)	中位数 显著偏低 (约 200-250 元)，但 高价异常点众多 。	“金字塔”结构 ：庞大的 高性价比/快时尚 主流市场 (拉低中位数)，同时并存 强大的高端消费群体 。
其他区域 (Other)	中位数居中 (约 230-280 元)，常规范围广，高价异常点广泛。	高度异质性群体 ，掩盖了内部 (如新一线城市) 的巨大差异， 整体消费潜力不容忽视 ，且 消费分化明显 。

核心发现 (基于客单价分布):

核心洞察:

- **高端消费普遍存在:** 各地域均有高价消费，非一线城市独有。
- **京沪引领:** 作为“第一梯队”，平均消费水平更高。
- **广东独特:** 体现了制造基地优势与大众市场特点，结构复杂。
- **“其他”崛起:** 潜力巨大，但需关注内部差异和消费升级趋势。

对城市性格的启示:


- **分层定位:** 针对不同地域特点，**差异化消费偏好**。
 - ✓ **京沪:** 主推高端、新品、体验。
 - ✓ **广东:** 兼顾性价比与时尚，挖掘高端。
 - ✓ **其他:** 抓消费升级，重品牌认知，细分市场。


结论: 客单价箱线图是理解地域服装消费差异、实现精细化运营的重要工具。

2.3.11 GMM 顾客细分 gmm_customer_segments()

此函数 `gmm_customer_segments` 的核心目标是基于省级宏观经济指标（平均房价、平均工资）和微观消费行为指标（平均客单价），为“北京”、“上海”、“广东”以及“其他”这四个地域群体绘制一个三维特征的雷达图，以便进行画像对比。函数最终会输出一个交互式的 HTML 文件和一个静态的 PNG 图片。


a) Python 代码逐步分析





b) 雷达图分析

北京 / 上海 / 广东 / Other – (客单价 × 100)



图注：雷达图展示了“北京”、“上海”、“广东”及“其他”四类地域群体在“房价(元/㎡)”，“工资(元/季度)”以及“客单价×100(元)”三个维度上的平均表现。

雷达图解读：房价、工资与客单价下的服装消费画像

目标：通过对比北京、上海、广东及其他区域的房价、工资和服装客单价，揭示其宏观经济背景与服装消费能力的关联。

核心发现 (基于雷达图):

地区	特征	解读
北京 (Beijing)	房价、工资 最高 ，客单价高。	高收入支撑 高购买力 ，服装消费偏向 中高端、品质化 。
上海 (Shanghai)	房价、工资 顶尖 ，客单价高 (与北京相当或略高)。	时尚之都 ，高收入驱动 高价值、国际化、潮流化 的服装消费。
广东 (Guangdong)	房价、工资、客单价 均为最低 。	(省级平均) 反映了 高性价比、快时尚主导 的大众市场特点，可能掩盖了内部巨大差异。
其他 (Other)	三项指标均处于 中间水平 。	混合群体 ，代表了 消费升级中的成长型市场 ，潜力巨大但需求多样。

核心洞察:

- **经济基础决定消费水平:** 高房价/工资与高客单价**强相关** (京沪 vs. 其他)。
- **京沪引领高端市场:** 是品牌定位高端、引领潮流的**风向标**。
- **广东市场大众化特征:** 体量大，但（平均）**价格敏感度高**。
- **“其他”区域是增长引擎:** 代表了广阔的**消费升级机会**。

结论： 雷达图清晰地展现了不同地域的宏观经济画像与其平均消费能力的关系，为制定**区域化服装市场策略**提供了重要参考。

2.3.12 城市词云 city_wordcloud()

- 合并同城评论，调用 WordCloud 生成形象化高频词。
- 自动寻找系统字体，避免中文乱码。
- 输出 wordcloud_北京.png / wordcloud_上海.png / wordcloud_广东.png。

```
wc = WordCloud(font_path=pick_font(), width=600, height=350)
wc.generate(txt).to_file(f"wordcloud_{city}.png")
```

三地词云图对比

城市	北京	上海	广东
词云图			
关键词核心特征	品质、形象与理性的成熟消费	设计、精致与国际化品味	务实、舒适与极致性价比
关键词解读	北京词云凸显了“品质驱动”与“形象导向” 品质至上：“质量好、有质感、做工精细”表明对材质、工艺的高要求。 形象关注：“好看、洋气、大气、显瘦”反映对审美与个人形象的重视。 舒适实用：“舒服、合适与百搭”说明舒适性与实用性不可或缺。 职业需求：“通勤、正式场合”显示职业装是重要消费场景。 理性考量：“值得购买、价格实惠”体现了成熟的性价比意识。	上海词云强调了“设计驱动”与“精致审美” 设计精致：“精致、设计感、优雅”是核心追求，对审美要求极高。 国际视野：“洋气、法式”反映了对国际潮流与特定风格的偏爱。 品质舒适：“质量好、面料舒服”说明追求时尚不牺牲品质与舒适。 个性修饰：“显瘦、显白”体现了对个人化效果的细致考量。 效率追求：“物流快”凸显对购物效率和服务的高要求。	广东词云最显著的是“性价比驱动”与“舒适实用” 极致性价比：“物美价廉、性价比高、便宜”是绝对核心，价格敏感度高。 舒适实用：“舒服、面料舒服、日常、百搭”表明体感与实用性是首要考量。 大众审美：追求“好看、合适”，但风格更偏大众化、休闲化。 品质底线：关注“质量好”，并非只看低价。 高性价比下的忠诚度：“多次购买”说明满足核心诉求后，复购意愿强。
画像总结	北京是 品质驱动、形象导向、兼顾舒适实用与性价比 的成熟消费市场，职业需求突出。	上海是 设计驱动、追求精致与国际风格、注重品质舒适、关注个性化并讲求效率 的时尚消费高地。	广东是 务实、追求性价比、舒适实用至上、偏好大众休闲风格 的市场，对“ 好穿不贵 ”有强烈需求。

2.3.13 小结

本章通过对京东平台 5 万余条商品评论数据的多维度深度挖掘与可视化分析，旨在系统性地揭示中国不同省市区域的消费偏好，并重点聚焦于理解各地的城市消费结构，尤其是在服装品类上的具体行为特征。

1. 显著的区域消费差异与梯度特征:

各项分析均清晰地展示了我国各省市之间在消费情感表达、用户粘性（如会员评论占比）、消费能力（体现在平均客单价、并与平均薪资和房价关联）、消费活跃度（RFM 模型中的 R 值和 F 值）以及具体品类（如服装）的消费偏好上存在显著的梯度性差异。总体呈现出东部沿海地区及一线城市在多个消费指标上领先，中西部地区展现成长潜力，同时也揭示了如广东等经济发达区域在特定消费行为上的独特性。

2. 一线城市（京、沪）的消费结构引领地位:

北京和上海作为中国顶级的消费城市，其居民在服装等品类上普遍展现出对高品质、强设计感、优良制作工艺和国际化潮流的极致追求。词云分析进一步佐证，北京消费者注重“品质”、“通勤”、“舒适”与“大气”，上海消费者则更突出“精致”、“设计感”、“时尚”与“优雅”。结合雷达图和箱线图数据，两地在高收入与高生活成本（房价）的背景下，其服装平均客单价和对“高级感”、“细节”等关键词的关注度均显著领先，职业与社交场合的品质着装需求旺盛，消费结构更为成熟和高端。

3. 广东省消费结构的独特性——务实与高性价比驱动:

广东作为经济总量巨大且服装产业链完善的地区，其消费行为呈现出与京沪显著不同的务实特征。词云分析强烈指向广东消费者在服装消费中极为看重“物美价廉”、“性价比高”和“舒适实用”，日常休闲需求突出。尽管其用户评论活跃度非常高（RFM 模型中的高 F、高 R 群体庞大），但在雷达图和箱线图中显示的省级平均客单价（尤其对比其经济体量）相对京沪更为平实，这反映了广东市场体量巨大下的大众化、高周转、追求实际效益的服装消费主导模式。

4. “其他”区域及中西部省份的成长潜力与消费升级趋势:

“其他”区域作为一个集合体，在会员渗透、消费活跃度和平均客单价上展现出追赶态势和巨大的市场潜力。箱线图和雷达图均显示，这些区域的平均客单价并不低，且存在大量高额消费的“异常点”。RFM 分析中的部分中西部省份（如四川、湖北、河南、安徽、江西等）已进入高价值或高潜力用户群，显示其城市消费结构正在经历快速升级，对品质和时尚的关注度日益提升。但这些区域内部差异亦十分显著，需要更细致的下钻分析和针对性策略。

5. 跨区域的共通消费关注点与服务期望:

尽管区域间消费偏好和结构差异明显，但在服装消费的核心要素上，如对产品本身的“满意度”、外观的“好看”、穿着的“舒服”、尺码的“合适”以及基础的“质量好”等，依然是各地消费者普遍关注的焦点。同时，如“物流快”、“客服”等服务体验相关的词汇在多地词云中均有体现，表明高效便捷的购物流程和良好的服务保障已成为影响消费评价和品牌口碑的共性关键因素。

综上所述，本章通过多维度、多工具的交叉印证和综合分析，不仅从宏观到微观描绘了我国主要区域及重点城市的消费画像，更深入探究了其消费行为背后的结构性特征与驱动因素。这些基于真实用户评论数据的洞察，为品牌商进行精准的市场细分、有效的区域产品定位、制定差异化的营销推广策略以及全面提升用户体验，提供了坚实的数据基础和有力的决策支持。

2.4 结论

本部分研究以国内主流电商平台京东（JD.com）的 54,701 条真实商品评论数据为基础，围绕“城市消费偏好结构”这一核心主题，成功地运用网络爬虫技术获取数据，并通过一系列数据清洗、整合、多维度分析及可视化手段，旨在深入洞察中国不同省市区域的消费特性与偏好差异，特别是聚焦于城市消费结构及具体品类（以服装为例）的消费行为模式。

核心研究发现与洞察：

1. 显著的区域消费结构差异与梯度特征：

各项分析均清晰地证实，中国各省市在消费情感、用户忠诚度（会员渗透）、消费能力（平均客单价，并受平均薪资、房价等因素影响）、消费活跃度（RFM 模型中的 R、F 值）以及具体品类（尤其是服装）的消费偏好上存在显著差异。总体呈现出东部沿海发达地区及一线城市在多个消费指标上领先，中西部地区展现出多样的成长态势，同时也揭示了如广东等经济发达区域在特定消费行为上的独特性（例如，在服装消费上更侧重性价比与务实需求）。

2. 一线城市（北京、上海）的消费引领与品质化、个性化追求：

北京和上海作为顶级消费城市，其居民在服装等品类上普遍展现出对高品质、强设计感、精湛工艺、优良体验和国际化潮流的极致追求。词云分析显示，北京消费者注重服装的“品质”、“通勤”适用性、“舒适”与“大气”；上海消费者则更突出“精致”、“设计感”、“时尚”与“优雅”，并对“法式”等国际风格有所偏爱。结合雷达图和箱线图数据，两地在高收入与高生活成本的背景下，其服装平均客单价和对“高级感”、“细节”等关键词的关注度均显著领先，表明其消费结构更为成熟、高端，且对服务效率（如“物流快”）有较高要求。

3. 广东省消费结构的独特性——务实、大众化与高性价比驱动：

广东作为经济总量巨大且服装产业链极为完善的地区，其城市服装消费行为呈现出与京沪显著不同的务实特征。词云分析强烈指向广东消费者在服装

消费中将“物美价廉”、“性价比高”置于核心地位，并高度重视“舒适实用”，日常休闲服装需求旺盛，“多次购买”的忠诚行为也基于此。尽管其用户评论活跃度非常高（RFM 模型中的高 F、高 R 群体庞大），但在雷达图和箱线图中显示的省级平均客单价（尤其对比其经济体量和人口基数）相对京沪更为平实，这反映了广东市场体量巨大下，大众化、高周转、追求实际效益的服装消费主导模式。

4. “其他”区域及中西部省份的成长潜力与消费升级趋势:

“其他”区域作为一个集合体，以及众多中西部省份（如四川、湖北、河南、安徽、江西等），在会员渗透、消费活跃度和平均客单价上展现出积极的追赶态势和巨大的市场潜力。箱线图和雷达图均显示，这些区域的平均客单价并不低，且存在大量高额消费的“异常点”，表明其城市消费结构正在经历快速升级，对品质和时尚的关注度日益提升。但这些区域内部差异亦十分显著，需要针对性的市场策略。

5. 跨区域的共通消费关注点与服务期望的提升:

尽管区域间消费偏好和结构差异明显，但在服装消费的核心要素上，如对产品本身的“满意度”、外观的“好看”、穿着的“舒服”、尺码的“合适”以及基础的“质量好”等，依然是各地消费者普遍关注的焦点。同时，“物流快”、“客服”等服务体验相关的词汇在多地词云中均有体现，表明高效便捷的购物流程和良好的服务保障已成为影响消费评价和品牌口碑的共性关键因素，是所有市场都需重视的环节。

研究局限与展望:

本研究亦存在一些局限性，例如数据主要来源于单一电商平台，评论数据本身是用户购买行为和使用体验的间接反映，且省级层面的分析可能在一定程度上掩盖了城市间的具体差异。

未来研究可考虑:

- **拓展数据源:** 纳入更多电商平台、社交媒体、线下消费等多渠道数据，构建更全面的消费画像。
- **深化品类分析:** 对更多不同商品品类进行专题性消费结构研究。
- **引入更多维度:** 结合更精细的人口统计学特征、地理位置信息（如城市级别）、生活方式等数据进行交叉分析。
- **动态追踪研究:** 进行长期的数据监测与分析，捕捉消费趋势的动态演变。

综上所述，本研究通过数据驱动的方法，为理解当前中国复杂且动态的城市消费市场提供了一个有效的分析框架和一系列有价值的洞察。这些发现不仅丰富了对区域消费行为的理论认知，更为相关企业在激烈的市场竞争中制定科学决策、实现持续增长提供了有力的实证支持。