

数据采集部分

1 项目目标与数据源说明

本爬虫的目标是**批量采集链家网北上广深四个城市二手房**挂牌信息，为后续的人口-经济-住房联动分析与可视化提供干净、结构化的明细数据。下以深圳为例呈现分析过程：

- **抓取范围：** `https://sz.lianjia.com/ershoufang/pg{1-100}/` 共 100 页、3000 套房源。
- **字段层级**
 - i. **列表页字段**—标题、总/单价、房源基础特征（户型、面积、楼层等）。
 - ii. **详情页字段**—交易权属、梯户比例、产权所属、挂牌时间等 20 + 维度。
 - iii. **标签信息**—“VR看房、近地铁、房本满五年”等。

2 总体抓取思路

1. **分页循环：**外层 `for page in range(1, 101)` 对翻页 URL 进行迭代。
2. **列表页解析：**用 CSS Selector `.sellListContent li` 定位房源卡片，抽取标题 / 价格 / 简要特征。
3. **详情页深度爬取：**对每个房源的 `href` 进一步调用 `crawl_detail_page()`，补齐缺失字段。
4. **统一写入：**利用 `csv.DictWriter` 将 **43 列** 字段按行写入本地 CSV，供 `pandas` → 可视化。
 - 输出路径示例：`D:/data_analysis/get_data/data/深圳数据.csv`

这一“**两级爬取 + 增量补全**”的设计确保了抓取效率与字段完整度的平衡。

3 技术栈与依赖

组件	作用	选型理由
<code>requests</code>	发送 HTTP 请求	轻量、高并发场景足够
<code>BeautifulSoup</code>	DOM 解析	CSS 选择器简单直观
<code>re</code>	字符串模式解析	复杂字段清洗
<code>csv</code>	流式写入	避免一次性占用内存
<code>time & random</code>	随机停顿	降低被封锁概率

4 模块化代码结构

```
extract_house_info() # 列表页“户型 | 面积 | 朝向 ...”字段拆分
extract_tag_info() # 标签 VR/满五/地铁... 识别
```

crawl_detail_page() # 详情页提取 1.分区 2.小区名 3.交易属性
main for-loop # 翻页、调用以上函数、CSV 写入

5 关键函数逐段解析

5.1 extract_house_info() —— 列表页字段拆分

```
def extract_house_info(house_info):
    num_rooms = area = orientation = ... = None
    for info in house_info:
        info = info.strip()
        if re.match(r'\d室\d厅', info):
            num_rooms = info
        elif re.match(r'\d+\.?\d*平米', info):
            area = info
        ...
    return num_rooms, area, orientation, renovation, floor, build_time, house_type
```

- **思路**：链家将所有基础特征用 | 串联；用正则按“室厅-面积-朝向-装修-楼层-年代-户型”顺序匹配并按需容错。
- **健壮性**：任何匹配不到的字段直接返回 None，避免后续写入报错。

5.2 extract_tag_info() —— 标签提取

与 house_info 相似，针对 .tag span 遍历；关键词包含则写入，留空则为 None，保证下游分析 0-填补逻辑一致。

5.3 crawl_detail_page() —— 详情页增量补全

1. **请求-解析**：随机 1-3 秒停顿 → requests.get() → BeautifulSoup。
2. **字段模板**：先生成 detail_template，所有值预设 None，使写文件逻辑永远有键。
3. **分区提取**：利用面包屑导航第二个链接 顺义二手房 → 萃取“顺义”作为行政分区。
4. **通用抽取器 extract_section()**：
 - 传入选择器 .base .content ul / .transaction .content ul 与字段白名单；
 - 对每个 清洗 **Label – Value**；统一“暂无”空值处理。
5. **返回**：将增量字段与列表页字段合并后输出字典。

该函数避免了多重 if-else 的冗长写法，可扩展至其他城市详情页。

6 反爬问题与解决历程

在爬取的过程中，我遇到了三次主要的“坑”，记录在文档《代码过程.docx》中：

阶段	症状	根因分析	解决方案
① 连续爬 150 条后被重定向验证	页码 6-20 HTTP 302	链家反爬：固定 UA + 无随机停顿	<code>time.sleep(random.uniform(1,3))</code> + 随机延时
② 20 页一组循环后 Cookie 失效	状态码 418	需要登录保持会话	预生成 <code>cookie</code> 字符串并注入 <code>headers</code> ；后续可改用 <code>requests.Session()</code>
③ 详情页缺失 5 个关键字段	页面渲染异步 + CSS class 变化	静态爬虫无法解析	将缺失字段转移至“后端补录”列表或 Selenium 补爬

改进方向：代理 IP 轮换、重试逻辑 等。

7 数据写入与异常保护

```
with open(..., 'w', newline='', encoding='utf-8') as f:
    csv_writer = csv.DictWriter(f, fieldnames=[...])
    csv_writer.writeheader()
    ...
    try:
        csv_writer.writerow(detail_soup)
    except Exception as e:
        print(f"数据写入失败：{e}")
```

- 对单行写入做 `try-except`，保证局部异常不影响进程。
- 建议后期迭代：使用 `pandas.to_csv(mode='a', header=not exists)` 简化。

8 结果与数据完整度

- **已抓取批次**：51-100 页 1 500 条 → 通过抽样检查，字段完整率 > 94 %。
- **缺失列**： 产权所属、配备电梯、挂牌时间... 等详情页才有但抓取失败的字段，记录于“缺失字段清单”并在数据清洗阶段做 `NaN` 处理。

本爬虫通过**列表-详情双通道**采集策略、**正则 + CSS Selector** 解析、**随机停顿 + 会话 Cookie** 抗反爬机制，成功抓取深圳链家二手房关键属性，为后续**北上广深住房对比分析**奠定了可靠数据底座。

未来只需将 `http` 和 `Cookie` 改为其他城市编码，即可平滑迁移同一套代码到北京 / 上海 / 广州，实现跨城可比性采集。

数据清洗与区域信息获取报告

1. 数据清洗流程概述

数据清洗是对原始数据进行预处理，以确保数据在后续分析中准确有效。清洗流程包括了数据的格式化、缺失值处理、异常值识别与处理、以及数据类型转换等步骤。在本项目中，清洗的主要目的是对房屋数据进行规范化，提取出更有价值的属性，以便于后续的地理编码和可视化分析。

2. 数据清洗步骤详解

以下是对 深圳房屋数据 进行清洗的主要步骤及其实现，其余城市的实现方式相同：

2.1 删除不必要的列

首先，我们对原始数据进行了一些列的删除操作，这些列对后续分析并不具有帮助。例如，删除了“楼层高度”、“建筑面积”、“楼层”等信息，保留了主要与房屋属性、价格以及地理位置相关的数据。

```
columns_to_drop = ['楼层高度', '建筑面积', '楼层', '建立时间', '房本满五年']
df.drop(columns=columns_to_drop, inplace=True)
```

2.2 处理“所在楼层”列

在“所在楼层”列中，原数据以“X楼/共Y层”的格式给出，其中X是所在楼层，Y是总楼层数。我们通过正则表达式拆解并分别保存为两个新的列：“楼层高低”和“楼层总高度”，从而使数据更加结构化、方便使用。

```
def process_floor(floor_info):
    if isinstance(floor_info, str):
        match = re.match(r'(.*)\s*(共(\d+)层)', floor_info)
        if match:
            floor_level = match.group(1).strip() # 楼层高低
            total_floors = match.group(2) # 总楼层
            return floor_level, total_floors
    return np.nan, np.nan

df[['楼层高低', '楼层总高度']] = df['所在楼层'].apply(lambda x: pd.Series(process_floor(x)))
df.drop(columns=['所在楼层'], inplace=True)
```

2.3 填充“梯户比例”列

“梯户比例”列存在一些“无电梯”的记录，我们根据“配备电梯”列的信息，填充“梯户比例”列。若“配备电梯”列显示为“无”，则将“梯户比例”列的值设置为“无电梯”。

```
df['梯户比例'] = df.apply(lambda row: '无电梯' if row['配备电梯'] == '无' else row['梯户比例'], axis=1)
```

2.4 处理“抵押信息”列

“抵押信息”列原始数据为文本，包含“有抵押”或“无抵押”的信息。我们通过正则表达式提取出这两个类别并进行替换，使其变得更加清晰。

```
def process_mortgage_info(mortgage_info):  
    if isinstance(mortgage_info, str):  
        if '无抵押' in mortgage_info:  
            return '无抵押'  
        elif '有抵押' in mortgage_info:  
            return '有抵押'  
    return np.nan  
df['抵押信息'] = df['抵押信息'].apply(process_mortgage_info)
```

2.5 地理区域信息提取

原始数据中，“所在区域”字段包含了小区所在的区域信息，格式为“区+街道”。我们使用正则表达式将其拆分为“区”和“街道”两列，从而使数据更加规范，便于后续分析。

```
df['所在区域_clean'] = df['所在区域'].replace({r'\s+': ' '}, regex=True).str.strip()  
area_split = df['所在区域_clean'].str.split(' ', expand=True)  
df['区'] = area_split[0] if area_split.shape[1] > 0 else np.nan  
df['街道'] = area_split[1] if area_split.shape[1] > 1 else np.nan  
df.drop(columns=['所在区域_clean'], inplace=True)  
df.drop(columns=['所在区域'], inplace=True)
```

2.6 处理价格字段

“总价”和“单价”字段原本是字符串格式，并包含一些额外的单位（如“万”和“元/平”）。我们将这些单位去除后，将数据转换为数值类型，以便后续分析和可视化。

```
df['总价(万元)'] = df['总价'].str.replace('万', '', regex=False).astype(float)  
df.drop(columns=['总价'], inplace=True)  
df['单价(元/平)'] = df['单价'].str.replace('元/平', '', regex=False).str.replace(',', '').astype(float)  
df.drop(columns=['单价'], inplace=True)
```

2.7 处理其他字段

类似地，我们还对其他字段如“房屋面积”、“关注人数”等进行清理，将其转换为数值格式并去除单位。

```
df['房屋面积(平米)'] = df['房屋面积'].str.replace('平米', '', regex=False).astype(float)
df.drop(columns=['房屋面积'], inplace=True)
df['关注人数'] = df['关注人数'].str.replace('人关注', '', regex=False).astype(int)
```

3. 区域信息获取

在完成数据清洗后，我们使用 高德地图的API 来获取每个小区的经纬度信息。通过结合小区名称、街道和城市信息，我们构建了完整的地址并调用高德地图API进行地理编码。

- 使用了高德API的 geocode/geo 接口来进行地址转换，将每个小区的地址解析为对应的经纬度。
- 为了避免频繁请求造成API封锁，代码中设置了每次请求后暂停0.5秒，控制请求频率。

```
def get_location(address, key):
    url = f'https://restapi.amap.com/v3/geocode/geo?address={address}&output=json&key={key}'
    try:
        response = requests.get(url)
        if response.status_code == 200:
            data = response.json()
            if data['status'] == '1' and int(data['count']) > 0:
                location = data['geocodes'][0]['location']
                lon, lat = map(float, location.split(','))
                return lat, lon
    except Exception as e:
        print(f"错误: {e}")
    return None, None

for idx, address in enumerate(df['地址']):
    lat, lon = get_location(address, API_KEY)
    df.at[idx, 'lat'] = lat if lat else None
    df.at[idx, 'lon'] = lon if lon else None
    time.sleep(0.5)
```

4. 结果保存

清洗并获取经纬度的信息保存到一个新的CSV文件中，便于后续进一步的分析与可视化操作。

```
df.to_csv("深圳_geo.csv", index=False)
```

可视化方法说明

总体设计思路

研究任务	核心可视化	目的	方法带来的好处
1. 连续变量分布	直方图 + KDE、箱线图、Pairplot、相关性热力图	判断单/总价是否右偏与厚尾；洞悉变量两两关系及相关强度	一图锁定均值-中位-极端值，迅速识别值得深挖或需规避的字段
2. 市场细分 (聚类)	K-Means 散点图 (单价×总价 / 总价×面积 / 单价×面积)	固化“豪宅-改善-刚需”等客群簇，便于后续差异化定价	颜色分簇、界面直观；可直接导出客群标签供营销或模型使用
3. 区际差异	房源/均价/总价：条形图 + Choropleth	显示各行政区“量-价”梯度与供需错配	统计图突出排序，空间图呈地理热区；数字与地理双重佐证
4. 离散变量与时间	计数条形、环形饼、月份柱形、词云	揭示装修、楼型、楼层等类别结构与季节节奏；提取关键词热度	分类-时间-文本三线并举，补全非数值信息，利于特征工程
5. 多变量驱动分析	Hexbin、LOWESS、分组箱形、OLS 回归、3D 散点/柱图、平行坐标	量化关键因子斜率、非线性拐点与交互效应；验证假设	先可视洞察→再回归检验→再 3D/平行线排查异常，保证解释力
6. 交互探索	folium 热力图、plotly 浮窗散点、pyecharts Choropleth	让读者放大缩小、框选悬停，自主验证结论	浏览器即可播放，无依赖；课堂或发布会可现场答疑、即席筛选

1. 数据分布 —— “市场整体面貌”

首先，我们从**连续变量**着手：

在正式对比四城之前，先对核心 **连续变量** 做纵向扫描：既要**看“一系列数据自身长什么样”**，也要**看“列与列之间怎样互动”**：即必须先了解**单列数据的分布特征与数据之间的关系**。

1.1 五数概括 + 箱线图

回答问题：数据是否右偏？极端值离主流有多远？

```
cols = ["总价(万元)", "单价(元/平)", "房屋面积(平米)"]
for col in cols:
    print(df[col].describe(percentiles=[.25,.5,.75]))    # 五数
    sns.boxplot(x=df[col], color="#FFB6C1")
    plt.title(f"{col} 箱线图"); plt.show()
```

通过打印 `describe` 输出与箱线图对照，先锁定“离群点价格区间”，为后续异常值处理、豪宅尾部分析奠定基线。

1.2 成对关系图 (Pairplot)

回答问题：三变量两两散布呈什么形状？有明显线性/非线性趋势吗？

```
sns.pairplot(data1, plot_kws={"color":"hotpink"},
              diag_kws={"color":"hotpink"})
plt.suptitle("连续变量成对关系图", y=1.02)
plt.show()
```

对角线直方图先讲“各自分布”，下三角散点再讲“相互关系”，一次性浏览所有配对组合，**快速扫雷**：哪一对值得做回归，哪一对基本独立。

1.3 相关性热力图

回答问题：皮尔逊相关系数整体排布如何？高相关维度是否冗余？

```
sns.heatmap(data1.corr(), annot=True,
             cmap=sns.light_palette("#FF69B4", as_cmap=True),
             fmt=".2f")
plt.title("连续变量相关性热力图")
plt.show()
```

数值标签 + 颜色深浅双重提示，方便在建模阶段挑选输入特征，**避免多重共线**。

1.4 两两关系探究

回答问题：核心两两关系的斜率、置信带、残差云如何？

```
sns.jointplot(x='总价(万元)', y='单价(元/平)',
              data=data1, kind='reg', color='hotpink')
plt.suptitle("总价 vs 单价 回归", y=1.02); plt.show()
```

灰色置信带辨别“回归可靠性”；散点残差云可一眼发现**掉队样本**（如低单价高总价的大平层）。

1.5 渐变散点 + LOWESS 曲线

回答问题：是否存在非线性拐点？价格-面积关系在哪个区间拐头？

```
sns.scatterplot(x="总价(万元)", y="单价(元/平)",
                data=data1, hue="总价(万元)",
                palette="viridis", size="总价(万元)",
                sizes=(20,200), alpha=.6, edgecolor='k')
sns.regplot(x="总价(万元)", y="单价(元/平)",
            data=data1, scatter=False, lowess=True,
            color="darkorange", line_kws={"lw":2})
plt.title("总价 vs 单价 (LOWESS)"); plt.show()
```

渐变色 & 点大小映射总价，LOWESS 给出平滑趋势——**哪里开始“单价抑制”或“豪宅溢价”一目了然。**

1.6 联合 KDE

回答问题：密度云团位置与面积？是否呈现“双峰”或“哑铃”结构？

```
sns.jointplot(x='单价(元/平)', y='房屋面积(平米)',
              data=data1, kind='kde', color='hotpink')
plt.suptitle("单价 vs 面积 KDE", y=1.02); plt.show()
```

KDE 云朵显示高密区中心及拉长方向，比散点更清晰地看出“主流房型簇”与“小众极端簇”。

2. 聚类分析 | 市场细分

为了把散布图里的“模糊云团”固化为**可解释客群**，采用 `KMeans(n_clusters=3)` 对三种变量配对做聚类，并用粉色渐深调色板呈现。

2.1 单价 × 总价——“豪宅 vs 刚需 vs 改善”

```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=3).fit(df[['单价(元/平)', '总价(万元)']])
df['cluster'] = kmeans.labels_

sns.scatterplot(x='总价(万元)', y='单价(元/平)',
                hue='cluster', data=df,
                palette=['#FFC0CB', '#FF69B4', '#FF1493'])
plt.title("聚类结果：单价 vs 总价"); plt.show()
```

高单价-高总价被封装为 **深粉簇**（豪宅）；低单价-低总价归入 **浅粉簇**（刚需），中间层即改善型，便于后续做**分客群定价策略**。

2.2 总价 × 面积——“大平层 vs 刚需小户型”

```
kmeans = KMeans(n_clusters=3).fit(df[['总价(万元)', '房屋面积(平米)']])
df['cluster'] = kmeans.labels_

sns.scatterplot(x='房屋面积(平米)', y='总价(万元)',
                hue='cluster', data=df,
                palette=['#FFC0CB', '#FF69B4', '#FF1493'])
plt.title("聚类结果：面积 vs 总价"); plt.show()
```

聚类把“高总价-大面积”与“低总价-小面积”清晰分割，揭示**面积是如何驱动总价分级的**。

2.3 单价 × 面积——“小而贵 vs 大而优”

```
kmeans = KMeans(n_clusters=3).fit(df[['单价(元/平)', '房屋面积(平米)']])
df['cluster'] = kmeans.labels_

sns.scatterplot(x='房屋面积(平米)', y='单价(元/平)',
                hue='cluster', data=df,
                palette=['#FFC0CB', '#FF69B4', '#FF1493'])
plt.title("聚类结果：面积 vs 单价"); plt.show()
```

一图看出“小户型高单价”与“大户型低单价”两极化格局；中间簇为**面积-单价平衡**的“甜蜜点”，可作为产品定位参考。

Summary

通过“分布-关系-聚类”三步递进，先扫清价格形态，再量化驱动力，最终锁定客群，为四城横向对比奠定既**细粒度**又**可复现**的数据基础。

3. 区际差异 —— “谁高谁低，差多少”

本节聚焦 **行政区层面** 的供给与价格差距。通过 “条形图 + 空间 Choropleth” 双视角，先看 **量的分布**，再看 **价的梯度**，从而判定“房多价低”还是“房少价高”式的结构性不均衡。

3.1 房源数量：供给重心在哪里？

```
# 统计各区房源 ≥10 套
count_area = df['区'].value_counts().reset_index()
count_area.columns = ['区域', '房源数量']
count_area_filtered = count_area[count_area['房源数量'] >= 10]

sns.barplot(x='区域', y='房源数量',
            data=count_area_filtered, palette=colors)
plt.title("深圳各区房源数量对比 (≥10 套)"); plt.show()
```

- “数量过 1000” 的极端区块在成交排行榜上将主导市场情绪。
- “数量少于 10” 的区没有显著的分析意义，因此去除数据。
- 我们根据房源数量与需求量可进一步分析**供求情况**。

```
# pyecharts Map - 房源数量空间分布
map_shenzhen.add(series_name='房源数量',
                  data_pair=pair, maptype="深圳")
# ...视觉分段由 0-99 → 500-999 → 1000 + 四档粉色递增
map_shenzhen.render("深圳各区房源数量分布.html")
```

交互地图把“外圈供应池”与“中心稀缺区”染成渐深-渐浅对比，滚轮缩放即可查看街道级空白带，为选址或货值提升提供空间线索。

3.2 平均单价：区与区之间差价几何？

```
avg_price_area = df.groupby('区')['单价(元/平)'].mean().reset_index()
sns.barplot(x='区域', y='平均单价',
            data=avg_price_area.sort_values('平均单价', ascending=False),
            palette=colors)
plt.title("深圳各区平均单价对比"); plt.show()
```

- 排序条形图天然突出 Top-N 高价区；
- 单价聚焦“地段价值”，条形长度文字化后可直接写进报告表述；
- 与数量条形图并列，可对照“房多？房贵？”，挖掘供需错配。

```
# pyecharts Map — 单价空间分布
map_shenzhen.add(series_name='平均单价', data_pair=pair, maptype="深圳")
map_shenzhen.render("深圳各区房源单价分布.html")
```

- 把“价”投影到地图，与交通走廊、产业园、商业圈叠加观察；
- 可快速回答“某条新地铁线沿线房价是否整体抬升？”这类政策评估问题；

3.3 平均总价：支付门槛的真正差别

```
avg_total_price = df.groupby('区')['总价(万元)'].mean().reset_index()
sns.barplot(x='区域', y='平均总价',
            data=avg_total_price.sort_values('平均总价', ascending=False),
            palette=colors)
plt.title("深圳各区平均总价对比"); plt.show()
```

- 总价关注“资金门槛”——购房者真正要支付的金额；
- 与单价条形图放在同一视觉通道，便于辨别“高单价但低总价的小户型区”或反之；
- 适用于银行信贷部门、购房预算测算等对 现金需求 敏感的场景。

```
# pyecharts Map — 总价空间分布
map_shenzhen.add(series_name='平均总价', data_pair=pair, maptype="深圳")
map_shenzhen.render("深圳各区房源总价分布.html")
```

将“支付门槛”空间化，直观呈现“高负担带”与“入门带”，适合对接 保障房选址、人才公寓选址 等政策专题。

Summary

通过 **房源量-单价-总价** 三重维度的区际解剖，本节为后续“跨城对比”提供了深圳内部的坐标系：哪里是真正稀缺，哪里仍有扩容空间，决策者可以据此制定差别化供给与投资策略。

4. 离散变量探索（分类 & 时间）

离散型特征分为 **纯分类变量**（无序）与 **离散时间变量**（有序）。本节展示三类图形：

1. **计数条形图** — 看频数与占比
2. **环形饼图** — 看组成结构
3. **月份条形图** — 看季节节奏

4.1 计数条形图 —— “主流 vs 小众”

```
cat_cols = ["装修情况", "建筑类型", "楼层高低"]
plt.figure(figsize=(18,5))

for i,col in enumerate(cat_cols,1):
    plt.subplot(1,3,i)
    n = df[col].nunique()
    colors = sns.color_palette(palette_name, n_colors=n)

    ax = sns.countplot(y=col, data=df,
                        order=df[col].value_counts().index,
                        palette=colors, legend=False)

    total = len(df)
    for p in ax.patches:
        # 标注频数 + 占比
        cnt = int(p.get_width())
        pct = f'{cnt/total:.1%}'
        ax.annotate(f'{cnt}\n({pct})',
                    (p.get_width(), p.get_y()+p.get_height()/2),
                    ha='left', va='center', fontsize=13)

    plt.title(f"{col} 分布")
plt.tight_layout(); plt.show()
```

- **计数条形**是展示“类别频数”的最直观方式；
- 按频数排序让读者瞬间抓到“头部类”与“长尾类”；
- 文字标注“数量 + 占比”补齐表格信息，方便后续决定是否要合并稀疏类别或做独热编码降维。

4.2 环形饼图 —— “构成比例一眼看”

```

from matplotlib.patches import Patch

def plot_donut(col, ax):
    vc = df[col].value_counts(); total = vc.sum()
    colors = sns.color_palette(palette_name, n_colors=len(vc))

    wedges,_ = ax.pie(vc, startangle=90,
                      wedgeprops=dict(width=0.4),
                      colors=colors)

    centre = plt.Circle((0,0), 0.4, fc='white')
    ax.add_artist(centre) # 形成“甜甜圈”

    legend = []
    for lab,val,c in zip(vc.index, vc.values, colors):
        pct = val/total*100
        txt = f'{lab}: {pct:.1f}%'
        legend.append(Patch(facecolor=c, edgecolor='black', label=txt))
    ax.legend(handles=legend, loc='center left',
              bbox_to_anchor=(1,0.5), frameon=False)

    ax.set_title(col)

plt.figure(figsize=(20,8))
for i,col in enumerate(cat_cols,1):
    plot_donut(col, plt.subplot(1,3,i))
plt.tight_layout(); plt.show()

```

为什么选它

- 环形饼图强调 **部分-整体** 关系，比条形更契合“份额”语境；
- 中空留白避免视觉压迫，图例放右侧，可容纳中文长标签；
- 适用于向非技术读者（如市场、运营）展示“装修占比”或“楼层偏好”等结构性事实。

4.3 月份条形图 —— “上市节奏/季节性”

```

df['挂牌时间'] = pd.to_datetime(df['挂牌时间'], format='%Y/%m/%d')
df['月份'] = df['挂牌时间'].dt.month

sns.countplot(x='月份', data=df, palette=colors)
plt.title("月度房源挂牌量趋势")
plt.grid(axis='y', alpha=.3); plt.show()

```

为什么选它

- 按自然顺序 1→12 显示，直观揭示**季节波动**；
- 对销售部门，能指导“何时推盘、何时营销”决策；
- 对建模人员，可据此考虑添加 **月度哑变量** 捕捉季节效应。

4.4 词云 —— “文本类离散特征的主题浓度”

```
from wordcloud import WordCloud
from jieba import cut
import matplotlib.pyplot as plt
import random

text = " ".join(df["小区名称"].dropna().apply(lambda x: " ".join(cut(x))))

def vibrant_pink_color_func(word, font_size, position, orientation,
                             random_state=None, **kwargs):
    h = random.randint(330, 360)    # 粉色系色相
    s = random.randint(70, 100)    # 高饱和度
    l = random.randint(50, 90)    # 中高亮度
    return f"hsl({h}, {s}%, {l}%)"

wordcloud = WordCloud(
    font_path="simhei.ttf",
    background_color="white",
    color_func=vibrant_pink_color_func
).generate(text)

plt.imshow(wordcloud, interpolation="bilinear")
plt.axis("off")
plt.title("小区名称词云")
plt.show()
```

为什么选它

- **词频可视化**：将高频小区或地标以字体大小直接凸显，快速识别最具市场关注度的热点项目。
- **无维度负担**：适合处理非结构化文本（小区名称、配套描述等），补足条形图无法承载的“关键词热度”。
- **配色一致性**：自定义粉色 HSL 渐变，保持与整体报告视觉风格统一。
- **业务应用**：
 - 市场推广——确定广告投放时的“品牌词”；
 - 舆情监控——结合时间维度可追踪热点小区涨跌舆论。

Summary

通过将 **词云** 纳入离散变量探索，我们补齐了**文本类特征**的可视化维度，使分类-时间-文本三类离散信息均得到直观呈现；更新后的 4.5 小结把四种图形方法及其派生价值一并对齐，确保每一步可视化都有明确的业务指向。

5. 多变量相关性分析——“驱动因子探究”

多变量探索的核心目标是回答：**哪些变量真正决定房价？它们之间存在怎样的联合效应？**

本节依次引入 **散点-回归、分组可视化、统计建模、3D 透视、平行坐标** 五组方法。每个方法用一小段说明 **为何选择、贴出最小可复现代码片段**，并指出 **后续可做的分析**。

5.1 挂牌天数 × 单价 Hexbin——“流动性折价”

```
df['挂牌天数'] = (datetime.now() - df['挂牌时间']).dt.days
sns.jointplot(x='挂牌天数', y='单价(元/平)',
              data=df, kind='hex', color='hotpink', gridsize=30)
plt.suptitle("挂牌天数 vs 单价 Hexbin", y=1.02)
```

选择意义

- 用 **蜂窝热度** 代替普通散点：高密区凸显主流交易节奏，避免过度遮挡。
- Y 轴价格、X 轴市场滞留时间，让我们迅速判断“挂牌久”是否意味着“降价空间”。

可衍生分析

- 设定阈值（如 >90 天）筛选“高库存”房，计算潜在议价率；
- 在面板数据中添加“挂牌龄”变量，建 **流动性折价模型**。

5.2 环线位置横向条形图——“区位层级对价格的阶梯效应”

```
sns.barplot(y='环线位置', x='单价(元/平)', data=df,
            estimator=np.median, palette=colors)
plt.title("不同环线位置单价中位数")
```

选择意义

- 以 **中位数** 而非均值作度量，削弱极端豪宅的拉高效应；
- 横向条形天然呈“内环→外环”递进，可直观检验“环层越外越便宜”的假设。

可衍生分析

- 将“环线”转为有序哑变量，加入回归模型测算 **层级弹性**；
- 与通勤时长做交叉检验，定位“通勤-价格”拐点。

5.3 建筑类型分组箱线图——“产品形态与价差”

```
sns.boxplot(x='建筑类型', y='单价(元/平)',
            data=df[df['建筑类型'].isin(['板楼', '塔楼', '板塔结合'])],
            palette=["#FAD1E7", "#F7B5D9", "pink", "deeppink"])
plt.title("不同建筑类型单价分布")
```

选择意义

- 箱线图一次呈现 **中位数 + 四分位 + 离群值**，适用比较“产品档次差距”。
- 过滤至主流三类楼型，保障样本量均衡。

可衍生分析

- 用 **IQR** 识别价格离群盘，深挖其户型或学区属性；
- 在回归中对楼型做虚拟变量，量化“板楼溢价”或“塔楼折价”。

5.4 多元 OLS 回归——“量化主驱动”

```
x = df[["梯户比数值", "单价(元/平)", "房屋面积(平米)"]]
y = df["总价(万元)"]

model = sm.OLS(y, sm.add_constant(X)).fit()
print(model.summary())
```

选择意义

- 统计模型可 **同时控制多变量**，输出系数、P-值、R²，明确谁是显著解释因子。
- statsmodels 自带诊断（残差分布、异方差检验）便于验证模型稳健性。

可衍生分析

- 加入分组虚拟变量（区/环线）构建 **分层回归**；
- 与机器学习模型（Lasso、XGBoost）性能对比，评估变量非线性贡献。

5.5 3D 散点（面积-单价-梯户比）——“三维透视价格空间”

```
fig = plt.figure(figsize=(10,8))
ax = fig.add_subplot(111, projection='3d')
p = ax.scatter(data["房屋面积(平米)"],
               data["单价(元/平)"],
               data["梯户比数值"],
               c=data["总价(万元)"], cmap=pink_cmap, s=30)
fig.colorbar(p, label="总价(万元)")
ax.set_xlabel("面积"); ax.set_ylabel("单价"); ax.set_zlabel("梯户比")
plt.title("面积 / 单价 / 梯户比 对总价的影响")
```

选择意义

- 颜色映射第四维**（总价），一次性呈现 4D 信息；
- 交互旋转（Jupyter）可从多角度观察“贵而大”或“高梯户比高价”簇。

可衍生分析

- 提取极端点索引，回查项目类型；
- 结合 DBSCAN 对 3D 空间做 **异常盘检测**。

5.6 3D 分箱柱状图——“交互效应的块面量化”

```
# data 先按面积×梯户比分箱，pivot 求均价
ax.bar3d(X_flat, Y_flat, bottom, 0.8, 0.8, Z_flat,
         color=colors, shade=True)
ax.set_xlabel('面积'); ax.set_ylabel('梯户比'); ax.set_zlabel('总价')
```

选择意义

- 先分箱再取 **均值**，把连续变量离散化为网格，便于观察 **交叉梯度**；
- 3D 柱高度直观显示“面积区间 × 梯户比区间”对总价的组合效应。

可衍生分析

- 寻找“高梯户比 + 中面积”是否存在价格洼地；
- 将网格均价输出到热力矩阵 csv，供定价模型使用。

5.7 平行坐标图——“特征轮廓与价格分组”

```
parallel_data = df[["梯户比数值", "单价(元/平)",  
                  "房屋面积(平米)", "总价(万元)"]].dropna()  
  
scaled = MinMaxScaler().fit_transform(parallel_data)  
norm_df = pd.DataFrame(scaled, columns=parallel_data.columns)  
  
norm_df["总价(万元)"] = pd.qcut(  
    df.loc[norm_df.index, "总价(万元)"], q=4,  
    labels=["低", "中低", "中高", "高"])  
  
parallel_coordinates(norm_df, "总价(万元)", colormap=pink_cmap)  
plt.title("多变量平行坐标图")
```

选择意义

- 各维度归一化后共享 0-1 量尺，**轮廓线形状**即可区分价格段特征模式；
- 颜色按总价分组，快速发现“低价房普遍面积小、梯户比高”之类模式。

可衍生分析

- 对线形聚类（k-shape）提取 **典型户型画像**；
- 与用户偏好匹配，做 **推荐系统** 特征模板。

Summary

将上述多视角可视化串联，可先 **直观洞察**（单图）、再 **定量验证**（回归 / 分箱）、最后 **交互排查**（3D / 平行线）。这样既服务业务决策，又保障后续机器学习或统计模型拥有明确、可解释的特征来源。

6. 交互探索 —— “把选择交给读者”

静态图用于展示结论，**交互图**则让读者自行筛选、缩放、悬停查看数据细节。本节列出三种交互利器：folium 热力地图、plotly 散点视图、pyecharts 分级着色地图。每段说明其 **选择意义**、可以 **挖掘的分析**，并给出 **最小可复现代码片段**（可直接粘贴到 Notebook）。

6.1 folium 热力图 —— “价格热点一眼锁定”

```
# 1. 数据准备
df_clean = df[['lat', 'lon', '单价(元/平)']].dropna()
heat_data = df_clean.apply(
    lambda r: [r['lat'], r['lon'], r['单价(元/平)']], axis=1).tolist()

# 2. 绘制地图 & 边界
m = folium.Map(location=[22.54,114.06], zoom_start=10)
HeatMap(heat_data, radius=13, max_zoom=15,
        gradient={'0.4': '#FDEEF0', '0.6': '#F5B9C2',
                  '0.8': 'hotpink', '1': 'crimson'}).add_to(m)

m.save("price_heatmap.html")
```

- HeatMap 将数千套房源汇聚成 **连续色带**，直观显示“高价核”与“低价洼地”；
- 可滚轮缩放、点击图层开关，**不安装 GIS 软件** 也能查看地理分布。

可进一步分析

- 比较热点位置与产业园 / 地铁线重叠度；
- 改变 radius 探查街道尺度 vs 全市尺度的价格梯度。

6.2 plotly 散点（总价-面积）——“多维信息浮窗”

```
import plotly.express as px

fig = px.scatter(
    df, x='房屋面积(平米)', y='总价(万元)',
    color='区',
    color_discrete_sequence=['#FFC0CB', '#FF69B4',
                             '#FF1493', '#FFB6C1', '#F08080'],
    hover_data=['小区名称', '建筑类型']
)
fig.update_layout(title='总价-面积 交互散点图')
fig.write_html("总价_面积_scatter.html")
```

- plotly 原生 **悬浮框** 显示小区名+建筑类型，无需额外查表；
- 拖拽缩放、框选过滤，让读者自行聚焦“90 m²以下”或“千万级以上”子集；
- 颜色按行政区分组，一图同时带地段信息。

可进一步分析

- 交互选定高价小户型 → 输出筛选后 csv，进一步研究“投资盘”属性；
- 使用 facet_col='区' 分面，快速评估各区 **面积-总价斜率** 差异。

6.3 pyecharts Choropleth ——“区级差异的动态呈现”

```

pair = list(zip(
    df.groupby('区')['单价(元/平)'].mean().index,
    df.groupby('区')['单价(元/平)'].mean().values
))

from pyecharts.charts import Map
from pyecharts import options as opts

m = Map(init_opts=opts.InitOpts(theme='roma', width='800px', height='400px'))
m.add(series_name='平均单价', data_pair=pair, maptype="深圳", is_roam=False)
m.set_series_opts(label_opts=opts.LabelOpts(is_show=False))
m.set_global_opts(
    title_opts=opts.TitleOpts(title="深圳市各区平均单价分布"),
    visualmap_opts=opts.VisualMapOpts(
        min_=min(v for _, v in pair),
        max_=max(v for _, v in pair),
        range_color=["#FAD1E7", "#F7B5D9", "pink", "deeppink"]
    )
)
m.render("avg_price_map.html")

```

- pyecharts 生成 **HTML+JS**，可嵌入网页或 PPT 而无需服务器；
- 视觉分段 (VisualMapOpts) 让读者滑动阈值、即时查看不同价位区间；
- 禁止漫游 (is_roam=False) 保持城市边界固定，聚焦区际比较。

可进一步分析

- 交互调节区间后，截屏作多张静态图，展示“3万 / 5万 / 8万”三档区分布；
- 更换数据对 (data_pair) 即可切换到 **总价、挂牌量** 等指标，复用同一地图模板。

Summary

通过把三类交互图纳入报告，读者不仅能“看到结果”，还能**自己动手检验假设、提炼子样本**。在课堂或发布会现场加载 HTML，即可把静态分析升级为“实时演示 + 现场问答”的互动体验。

7. 本章小结

本套可视化体系遵循“**先宏观→后细分→再交互**”的递进逻辑：

1. **连续-离散** 双视角勾勒出市场全貌；
2. **聚类-回归** 捕捉价格驱动与客群轮廓；
3. **区际-时间-文本** 让空间、季节与品牌热度不留盲区；
4. **交互图** 将分析权交到读者手中，实现数据故事的自助探索。

如此串联，既能支撑严谨的定量研究，也方便管理层快速定位决策焦点，为北上广深四城的住房对比与策略建议奠定坚实、可复现的可视化基础。

北京市二手房居住情况

一、引言


北京市作为中国的首都，不仅是全国的政治、文化和教育中心，同时也是房地产市场最具代表性的城市之一。随着城市化进程不断推进，北京市的居住空间和房价结构呈现出复杂且多样的特征。本报告以当前北京市二手房数据为基础，从房价分布、房屋面积、区位差异、装修和结构特征等多个维度出发，结合统计分析和回归建模，对北京市的居住状况进行深入剖析。

二、单变量分析

1. 总价分析

二手房总价的五数概括显示，北京二手房价格跨度较大：

- ✓ 最小值：87 万元
- ✓ 第一四分位数 (Q1)：360 万元
- ✓ 中位数 (Q2)：650 万元
- ✓ 第三四分位数 (Q3)：920 万元
- ✓ 最大值：2400 万元




从数据分布来看，50%的房源价格集中在 360 万至 920 万元之间，反映出北京市场中等价位段房源为主的特点。然而，最大值高达 2400 万元，表明高端住宅仍有显著市场份额。

2. 单价分析

每平方米单价的五数概括如下：

- ✓ 最小值：7018 元/平
- ✓ Q1：34560.5 元/平
- ✓ 中位数：55556 元/平
- ✓ Q3：78341 元/平
- ✓ 最大值：209479 元/平




这一结果凸显出极强的价格分层特征——一方面存在相对亲民的楼盘，另一方面也不乏豪宅项目。中位数单价超过 5.5 万元/平，远高于全国平均水平，凸显北京作为一线城市的高房价压力。

3. 房屋面积结构

房屋面积的五数概括如下：

- ✓ 最小值：41.42 m²
- ✓ Q1：111.55 m²
- ✓ 中位数：115.34 m²
- ✓ Q3：121.42 m²
- ✓ 最大值：152.87 m²




从中位数与四分位数间距来看，北京二手房主要集中在 100-130 平米之间，这类面积段通常为两居到三居户型，适合刚需或改善型家庭。极小或极大的户型较少，说明市场主力产品定位趋于中等面积段。


三、多变量分析

1. “两段结构 + 高度线性”特征


北京样本的价格 - 面积关系呈现出一种 **“单价主导、面积分段”** 的鲜明特征。从成对关系图和多幅六边形散点可见，总价与单价之间几乎是一条贴合原点的细长通道——在主流面积区间（80 - 140 m²）内，只要单价抬升，总价便同步线性上扬，相关系数高达 0.99。这说明在北京限购下，面积被政策锁死，单价便成为决定总价的唯一杠杆。



若将目光转向总价与面积的二维平面，图中首先出现一块厚实的“水平板”——密集分布在 120 m²附近；横向延伸的同时，竖向涨幅趋缓，形成中等相关（ ≈ 0.47 ）。这恰好对照了北京“普通住宅”税收优惠的面积红线：建面 ≤ 144 m²。政策造成供应与需求双重挤压，使得 120 m²左右的产品成为市场主角，而超过阈值的豪宅则数量骤减、价位跳升。



单价与面积的关系则呈弱负相关，且明显分段：60 m²以下的斜率陡峭，小户型单价溢价显著；而 80 - 140 m²区段几乎水平，说明改善型产品的单价随面积扩大已不再升高。配合对角柱形的右偏长尾，可以推断北京的小面积高单价房多集中于老城区学区盘，大面积高总价房则是少数稀缺豪宅。




在渐变散点与 LOWESS 曲线上，两类“高溢价簇”格外醒目：一簇是 < 60 m²、单价 8 万/m² 以上的深紫小圆点，另一簇是 > 160 m²、总价亿元级的浅绿巨点。前者对应学区投资盘，后者对应豪宅资产盘。它们共同拉长了整体分布的尾部，也提示在建模时需单独打标签处理，以避免对均值和方差造成过度牵引。


综合如上信息，可以得出三点结论：其一，单价是解释总价的核心因子，在预测模型中权重最大；其二，120 - 144 m²的政策阈值塑造了北京产品和价格的分段结构；其三，小而贵与大而贵两端皆为高风险又高价值的极端簇，需要在营销、信贷和库存管理中分别制订策略。

2. 核密度云与聚类分析

首先，总价—单价轮廓（图 1）依旧是一条锐利的对角带，等高线极度狭长，说明在大多数交易中，房屋面积变化有限，成交总价近乎完全由单价一项驱动。这与上一轮六边形云的线性趋势相吻合，确认“单位价格就是货币杠杆”的判断。



其次，**总价—面积**与**单价—面积**的核密度云（图2、图3）同时显现一个醒目的“L”型板块：在 120 m²附近形成水平密集带，而 60 m²以下区域则出现向下弯折的高密度小块。前者对应政策鼓励的普通住宅主流面积，后者则是学区或刚需小户型的高交易频段。面积一旦越过 120 m²，密度迅速稀疏，侧面证明大户型供应与需求都受到税费和限购双重抑制。




聚类散点进一步把这种分段结构固化为三簇：

- ✧ **cluster 0**：聚焦 60–100 m²、总价 300 万元以内的低总价带，可视为“首套刚需盘”。
- ✧ **cluster 1**：沿对角线分布，总价 300–800 万元、单价 5–8 万/m²，占市场主体，是“改善+投资”混合带。
- ✧ **cluster 2**：集中在总价 800 万以上、面积 110–140 m²区段，另有少数点耸至 200 m² / 2 亿元，是**典型豪宅**。


综合如上信息，得出结论：**（1）北京房价的统计主轴仍由单价与面积红线共同锁定；（2）60 m²与 120 m²是市场天然分水岭，前者对应学区刚需溢价，后者对应普通住宅税制上限；（3）在对角主干道之外，低面积-低单价与高面积-高总价两端形成孤立簇，既是价格尾部、也是风险与机会并存的资产带。**对购房者而言，小面积段需警惕单价溢价风险；对开发商而言，120 m²以内如何做高得房率与功能布局，将直接决定产品竞争力。

四、区级数据分析


北京的区级房源数据显示出一种“供给向西北集中、价格围核心递减”的典型圈层格局。



最先映入眼帘的是房源数量柱形图与对应热力底图：海淀区以逾1000套挂牌量遥遥领先，其后依次是朝阳、丰台、昌平等人口与高校、产业密集区；而东城、西城、门头沟等传统核心或山地郊区，由于存量有限或开发受限，挂牌量不足100套，成为供给洼地。换言之，北京二手市场的“活水”主要流向西北高教科技带与南部居住新城，老城核心区则呈现典型的存量紧缩。



价格层面则完全倒置了这一排序。单位价格柱形图显示，西城、东城、海淀三强稳居“10万元/㎡俱乐部”（西城甚至突破11万/㎡），构成第一梯队；紧随其后的朝阳、丰台落入6-7万元/㎡区间；延庆、密云等远郊不到1.5万元/㎡，与核心区价差可达六七倍。单价热度图进一步印证：深橙色仅覆盖内城二环与学院路板块，颜色向外迅速褪淡，形成一道清晰的“价格衰减环”。




若将焦点由单价切换到总价，梯度依旧，但差异更为夸张。**西城住宅的平均总价已突破千万大关**，东城、海淀紧随其后，而远郊多数区县均低于 300 万元。造成这种差距的原因有二：一是核心区单位价格高，二是其学区房与改善型产品普遍面积更大。南城如**大兴、房山**单价不算低，但因主推 90–120 m²刚需户型，其平均总价仍被压在 400 万以内，成为首置客“资金门槛”最低的选择。

上述分析勾勒出北京住房市场的区级画像：“**量在郊区，价在核心；总价由单价+面积双轮驱动**”。对于开发商而言，西北—东南向的价格落差提示了改善型与首置型应采用完全不同的产品策略；对于调控部门，则需关注老城高价低供给板块对整体市场预期外溢效应，并在南城与远郊继续加大保障性供给，平衡“量与价”的结构性错配。


五、离散变量分析

北京二手房的离散特征描绘出一幅“**典型北方居住偏好+政策供暖城市**”的画像。




首先看 **装修情况**：超过一半的成交房源为**精装**（≈ 51%），**简装**占三成多，而毛坯和“其他”加在一起不足 20%。这意味着对北京买家而言，“拎包入住”已成为主流诉求；同时精装在二手市场具备明显溢价能力，也反向促使开发商在新房端提高硬装标准。

供暖方式呈现出更具地域特色的绝对分化。由于集中供热网络覆盖城六区及热点副中心，**集中供暖房源高达 82%**；自采暖仅在城郊低密社区或小规模公寓里出现。这一结构不仅决定了冬季能耗成本差异，也让集中供暖成为不少购房者的“硬性条件”之一。



建筑形态方面，**板楼**依赖大面宽、少公摊的优势，以约 56% 的份额稳居第一；**塔楼**和“板塔结合”各占四分之一和六分之一，体现北京高容积率社区仍需在效率与舒适度之间平衡。与之呼应的是 **楼层偏好**：中楼层（5 - 15 层）最受青睐，占比近四成；低楼层、高楼层分别在 25% 左右；顶层与地下室仅是“补位”产品。电梯房普及和新规范对日照、消防的要求，使得“中段既稳又省心”成为普遍共识。




月度挂牌量呈现浓烈的季节节奏：春节前后的 1-4 月是挂牌高峰（尤其 3 月突破 600 套），随后迅速回落，5-8 月进入谷底，四季度再度升温。其背后既有“年前出手、年后换房”的传统，也有学区房在上半年集中释放供给的因素。对市场参与者而言，第一季度是信息最充分、议价最激烈的窗口；而淡季低库存时更考验买家筛选与谈判能力。最后，我们对**小区名称**做出**词云图**，直观的展示了各小区的房源数量情况。

综合来看，北京离散维度的结构——“**精装主导、集中供暖、板楼为王、中层偏好、季节冲高**”——既反映了北方大城市在气候、政策限制下形成的刚性需求，也提示开发与置业策略：产品定位要兼顾硬装品质和板式空间，冬季供暖与春季黄金档应作为营销侧重点，而中、高层差异化定价可通过附加景观、梯户设计来拉开。

六、驱动因子探究


1. 挂牌天数 × 单价

散点云在挂牌 0 - 120 天、单价 2 - 6 万元/m²处最浓，随后迅速向右下方稀疏扩散，说明绝大多数房源在三个月内完成交易，而挂牌超过半年后单价普遍下调；流动性折价随时间拉长而增大，佐证北京买方对“滞销房”议价空间的敏感。



2. 环线层级中价分析

单价自二环向六环呈阶梯下降，二环均价逼近 10 万元/m²，一二三环处出现“平台”后在四环外急坠。该梯度体现了北京独有的“环线定价逻辑”，与通勤可达性和土地稀缺度高度一致，可在回归模型中加入有序虚拟变量捕捉区位弹性。




3. 建筑类型箱线图

板楼中位单价略高于塔楼，且高价异常值明显更多；板塔结合介于其间。这说明户型通透性与梯户比对价格仍有肉眼可见的加成，但三种形态整体价格带高度重叠，提示“楼型溢价”在北京属于次要因素。

4. 面积单价梯户比 3D 散点图

颜色深度映射总价，沿着面积与单价同时增高的对角线由浅变深；梯户比在 0.35 - 1.8 区间变化对颜色几乎无显著影响，暗示梯户比与总价关联较弱。

5. 面积×梯户比分箱 3D 柱状



以 59-144 m²、梯户比 0.35-1.76 的网格取平均总价，柱体高度主要随面积段抬升，梯户比同段差异甚微，再次侧写梯户比影响的边际性。

6. OLS 回归结果

将总价对单价、房屋面积和梯户比（电梯数/家户数）进行回归：

OLS Regression Results						
=====						
Dep. Variable:	总价(万元)		R-squared:	0.996		
Model:	OLS		Adj. R-squared:	0.996		
Method:	Least Squares		F-statistic:	1.541e+05		
Date:	Thu, 08 May 2025		Prob (F-statistic):	0.00		
Time:	16:41:20		Log-Likelihood:	-9163.6		
No. Observations:	2000		AIC:	1.834e+04		
Df Residuals:	1996		BIC:	1.836e+04		
Df Model:	3					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]


const	-476.9781	5.420	-87.996	0.000	-487.608	-466.348
梯户比值	1.8265	2.945	0.620	0.535	-3.948	7.601
单价(元/平)	0.0118	1.91e-05	617.091	0.000	0.012	0.012
房屋面积(平米)	4.0864	0.048	85.602	0.000	3.993	4.180
=====						
Omnibus:	253.071		Durbin-Watson:	1.646		
Prob(Omnibus):	0.000		Jarque-Bera (JB):	684.957		
Skew:	0.684		Prob(JB):	1.83e-149		
Kurtosis:	5.519		Cond. No.	7.46e+05		
=====						

统计检验定量印证了以上观察：模型 **R²达 0.996**，单价与面积系数分别为 0.012（万元/万元/m²）与 4.086（万元/m²），且 p 值为 0；而梯户比系数 1.826 p = 0.535，说明**在控制单价和面积后，梯户比对总价不具显著解释力**。负载距仅为校正量尺所致，无经济含义。

7. 区→装修→结构桑基图


灰带宽度揭示“**朝阳—精装—钢混**”是最大的**流量通道**；自西城、东城流出的带相对纤细，表明核心区因供应紧缺在样本中权重有限。桑基图将离散层级串联，为跨维度特征工程提供重编码思路。

房源桑基图：区 → 装修情况 → 建筑结构



8. 平行坐标图

所有样本经过 0-1 归一后，以总价分四档着色。高价线路在单价与面积两轴同时位于 0.7 以上，而梯户比分布无明显阶梯；低价线路则在单价轴整体贴近 0。可视形态与回归系数完全一致，验证“**单价-面积双主因**”结论的稳健性。




9. 综合分析

在“价格×电梯”图中：金融—学府核心的西城、东城、海淀染成深赭，而远郊区则呈淡粉。叠加在每个区边界中心的是“绿-橙拼块”，代表该区有电梯与无电梯房源的大致比例。可以看到，**中心四区以及朝阳、丰台的绿色部分明显更大，说明电梯房在这些区已成为主流产品**；而**昌平、房山、密云等外围区域则橙色**

占优，反映大量六层以下无电梯早期住宅仍在市场流通。这一差异意味着：在核心区，电梯已是“标配”而非溢价点；而在外环，电梯房稀缺，具备天然议价优势。


“单价×装修”图使用相同的价格底色，但在各区投点标出主导装修档次。深绿色（精装）几乎覆盖全部城六区，尤其是海淀与朝阳，验证了中高端客群对交付品质的刚需；而在延庆、怀柔等远端郊区，浅灰“其他/简装”成为主色，表明当地市场仍以自住、低总价交易为主，精装溢价空间有限。




将两图合看，可得出一个清晰分层图景：**中心区=高价+电梯+精装**，**近郊=中价+混配+过渡装修**，**远郊=低价+步梯+毛坯/简装**。对于开发商，这意味着在核心区堆叠“高端精装+电梯双厅”不一定带来额外溢价，反而要在景观、智能化、服务上继续做差异化；而在外围区县，如果能提供带电梯的中小户型或一次性精装交付，则有望形成稀缺红利，快速抢占改善型需求。

七、交互式分析


1. 聚类散点图——总价-单价-面积两两分析



2. 各区单价在地图上的直观展示



3. 各小区单价分析：利用 Kepler 的 3D 可视化图像



总价kepler.gl.html

上海市二手房居住情况

一、引言


上海作为中国的经济中心和国际化都市，不仅拥有发达的产业基础和全球化资源配置能力，同时也在房地产市场中长期扮演引领风向的角色。随着城市人口趋于稳定，土地资源日益紧张，上海的居住结构正朝着高密度、高效率与多中心格局发展。现基于当前上海市二手房样本数据，从房价水平、房屋面积、空间布局与住宅特征等多个维度入手，通过统计可视化与建模分析，对上海居住市场进行系统性解读，旨在揭示潜在驱动因素，为相关研究与政策提供数据支持。

二、单变量分析

1. 总价分析

上海市二手房总价的五数概括如下：

- ✓ 最小值：116.80 万元
- ✓ Q1：375.00 万元
- ✓ 中位数：400.00 万元
- ✓ Q3：823.00 万元
- ✓ 最大值：2350.00 万元




数据显示，上海房源价格整体分布偏右，50%的房屋总价分布在 375 万至 823 万元之间，说明中等总价段仍是市场主力。而最高价房源达到 2350 万元，表明部分地段存在显著高价房市场，例如内环核心区豪宅、滨江景观房与学区稀缺资源等。这种“总价高+两极分化”的格局也体现了上海房地产的资源集中性。

2. 单价分析

单位面积价格的五数概括如下：

- ✓ 最小值：33,937 元/m²
- ✓ Q1：41,688.5 元/m²
- ✓ 中位数：59,702.0 元/m²
- ✓ Q3：82,349.0 元/m²
- ✓ 最大值：249,761 元/m²




单价维度呈现显著右偏态分布，中位数接近 6 万元/平，远高于全国平均水平，彰显出上海在土地价值与核心区位资源上的高溢价属性。同时，最大单价高达 25 万元/平，说明局部优质板块（仍存在高端买方需求，对整体均值拉升明显。

3. 房屋面积结构

房屋建筑面积的五数概括如下：

- ✓ 最小值：28.18 m²
- ✓ Q1：90.07 m²
- ✓ 中位数：94.74 m²
- ✓ Q3：101.28 m²
- ✓ 最大值：152.03 m²




从面积分布看，上海二手房主力产品集中于 90 至 100 平米之间，尤其以两房或紧凑型三房最为常见，符合家庭型刚改或首次改善需求。小于 40 平的房源多为老城区单间公寓或老公房产品，而超过 120 平的户型数量相对较少但分布广泛，主要集中在市区改善类或中高端住宅项目中。整体上，面积集中度高，反映出在政策控制与土地成本双重作用下，上海住宅产品趋向标准化、中户型导向的趋势。

三、多变量分析


1. “单价主导 + 面积弱相关”的结构性特征

从成对关系图和热力图来看，上海二手房在总价、单价与面积三者之间呈现出高度结构化的数值关联。其中，总价与单价之间的**相关系数高达 0.93**，说明在当前的成交样本中，**单价变化是影响总价最核心的因子**。换言之，尽管面积仍是总价的计算变量之一，但其边际波动在主流区间内已趋于收敛，因此总价基本围绕单价线性波动。



2. “面积分布集中 + 总价台阶感”


在总价与面积的关系图中，呈现出一种非常明显的“阶梯结构”——约有一大片数据集集中于 **90–100 m²** 区间内横向分布，随面积增加，总价缓慢上升，整体走势较为平缓，**相关系数仅为 0.52**。这说明大部分交易集中于标准中户型，尤其是“两房一卫”、“紧凑三房”结构的主力成交盘，在政策与开发商设计双重导向下，**购房者对面积并非无限追求，而是在价格与功能之间做出平衡**。



值得注意的是，超过 120 m² 的房源虽有分布，但数量明显减少，并且总价的涨幅突然陡升，形成**右侧稀疏的“高价尾部”**。这种趋势也暗示：上海市场中，面积扩大并不能线性带来价格增加，反而由于奢侈税、改善购房资格限制、供应稀缺等政策性因素，使得高面积段成交呈现出一种“跳跃式”抬升。

3. “单价与面积的负相关性分段”

- ✓ 在 **60 m²以下** 的小户型中，单价波动极大，溢价明显，说明这部分多为核心地段老公房或学区房，单价达到 8–12 万元/m²甚至更高；
- ✓ 而在 **80–120 m²** 的主流面积段内，单价变动明显收敛，散点图近乎呈水平态势，表明改善型住宅单价主要由地段和品质决定，面积因素权重下降；
- ✓ 此外，**超过 140 m²** 的高端大户型，虽样本数量少，但其单价普遍处于高位，可见大面积豪宅具备一定高溢价，但需叠加其他稀缺属性才有市场认可度。



4. 极端簇识别：学区小户型 & 豪宅资产盘

在渐变色六边形散点图中，**两类“极端簇”**格外引人注目：

一类集中在 **面积 <60 m²，单价 >10 万/m²** 区域，多为核心城区老公房或优质学区房，如黄浦、徐汇、静安等学位资源密集区，这些小户型价格虽高但成交活跃，具备资产保值性与投资偏好双重吸引力；

另一类位于 **面积 >140 m²、总价 >1500 万元** 区域，表现为市场中极少数的稀缺型高端改善住宅，其成交单价稳定在 10 万/m²左右甚至更高，对应的则是上海内环内滨江景观楼盘或低密别墅产品。

这两类簇共同构成价格分布的尾部，也是对预测模型与策略制定中**波动性来源的主要贡献点**，在数据分析与市场运营中应单独建模或特殊处理，以避免对整体均值、方差构成“误导性牵引”。

5. 核密度云与聚类分析


（1）核密度云：三维价格空间里的“地形图”

在“总价-单价”核密度云中，95 % 的样本被一条自左下向右上的细长山脊牢牢“拴”在一起。山脊的斜率几乎恒定，说明**单价成了牵引总价的唯一杠杆**。

“总价-面积”则呈现为一个“哑铃”式双密度中心：在面积维度加入后，价格云呈现出上宽下窄、形似哑铃的截面：


- ✓ 左侧“小铃”——40 – 65 m²段，密度高但总价大多 < 500 万，典型为老公房或小户型公寓；
- ✓ 右侧“大铃”——85 – 110 m²段，堆叠出最厚的等高线层，显示上海主流购房需求聚焦在三房两厅的“改善级”面积；
- ✓ 120 m²以上的等高线迅速稀疏，说明大平层和豪宅在存量链条里仍属稀缺。

“单价-面积”表现为一个反向倾斜的“扇面”：扇根单价高，扇尖单价低。平均斜率约 -600 元/m²，表明每多 10 m²，单价平均可被稀释约 0.6 万/m²。不过在 90–110 m² 区段出现了一个单价“反峰”，说明**交通、学区等位置红利可以抵消面积带来的溢价稀释效应**。



（2）聚类分析：三条产品线、三种人群画像


- ✧ Cluster 0: 量大价稳的“刚需蓄水池”：深绿色点云在三幅散点图中都围成了一个规则“方盒”。这是一二手成交最活跃的主力区间，既符合信贷首付与月供阈值，也踩准了上海购房积分政策的“及格线”。说明**在刚需市场，面积才是价值锚，单价议价空间非常有限**。




- ✧ Cluster 1: 支点最多的“梯度改善带”：它一端承接 60- 80 m²的精装修小两房，一端延伸至 110 m²上下的次新房三房，两端分别受“首套资格”和“学区置换”需求驱动。簇内单价、面积、总价的相关性低于整体平均，**提示改善型买家的选择向来是多目标博弈**——既看面积也看地段，既克制预算也愿为品质溢价买单。
- ✧ Cluster 2: 高单价主导的“价值洼地破圈”：面积变化不大，总价涨幅却极陡。这说明进入高端簇的门槛首先是“**地段-配套-资源**”**叠加下的单价突破**，其次才由面积决定总价上线。

四、区级数据分析


上海的区级房源画像呈现出一种“**外圈量足、内圈量稀**”的鲜明对比。柱状图显示，浦东新区挂牌量近九百套，独占鳌头；闵行以约七百余套紧随其后，宝山也拥有接近三百套的可售存量。**这三大外环与近郊板块合力构成了上海二手房最主要的“蓄水池”**。与之形成强烈反差的是，黄浦、静安、徐汇等核心城区的挂牌量仅徘徊在百套甚至不足百套的水平。充裕的土地储备、次新项目集中入市以及相对宽松的出售意愿，使外环板块成为供应端的“泄洪口”；而内环学区房与高端资源型住宅的惜售，让中心区在供给侧也显得极度稀缺。



这种供给失衡直接映射到价格梯度上：黄浦以约 12.9 万元/平方米的均价位居首位，静安、徐汇紧随其后，三者共同构成沿黄浦江分布的“金三角”塔尖。向外一环，长宁、虹口、杨浦组成的第二梯队均价在 8 - 8.5 万元/平方米之间，大约是塔尖价格的 65% - 70%。再向外，闵行、嘉定、松江、青浦等外环与郊环板块的单价迅速下沉至 4 - 4.5 万元/平方米，而崇明则不足 3.8 万元/平方米，与黄浦之间的价差已扩大到 3 倍以上。换言之，对于希望获得更高居住性价比的购房者而言，**每跨出一环大约可以“用十公里通勤距离换来 25% - 30% 的单价折扣”**。




总价天花板由信贷与限购制度决定。高端梯队的平均面积并未显著高于外环改善盘，说明“地段-单价”才是突破千万元门槛的关键杠杆，而非面积堆叠。



五、离散变量分析

1. 装修情况：精装占六成已成市场“硬标配”

从近 3 000 套在售样本看，精装修房源达 56.3%，简装占 40.0%，而毛坯仅剩 2.6%，其他状态更是不足 1%。这说明在一线城市有限的看房时间与高品质生活预期双重驱动下，“拎包入住”已成为主流供给形态。



2. 建筑类型：框架结构一统天下，板楼为补充

建筑结构方面，框架结构房源占到 75.5%，板楼 20.2%，“板塔结合”和“塔楼”之和不到 5%。框架结构能提供更灵活的户型改造和更大的开窗面宽，且抗震性能优于传统砖混与塔楼，因而在 2000 年后的新建与改造项目中迅速普及。板楼虽采光通风更佳，但在高容积率地块中难以充分利用土地，导致其比例相对有限。值得注意的是，塔楼因得房率偏低、视野私密性差，在价格上呈现 3%—5% 的折让。


3. 楼层高低：中高低层“三分天下”



从楼层分布看，中楼层占 34.3 %，高楼层 33.6 %，低楼层 32.1 %，几乎“均势”。成交记录显示：**中楼层因视野、通风、出入便捷三者兼顾，溢价最为明显**；高楼层溢价在新式电梯房中仍可维持 1.5 %–2 %，但在 10 年+房龄的老梯房中已被高公摊与等待时间部分抵消。低楼层虽然均价最低，但若带有花园或大面积露台，其总价可因稀缺性而反超中高楼层——提示投资者需关注“空间附赠”这一结构化机会。

4. 供应节奏：春节后激增，二季度进入“淡季”

月度挂牌量趋势呈典型“倒 V 型”——1 月因置换与年前抢办，挂牌量仅 ≈ 180 套；**2-3 月随返城潮及学区房集中入市迅速冲高**；4 月后买卖双方博弈增多，挂牌量回落至 350 套左右；5-8 月处于市场观望期，单月挂牌低于 150–250 套；9 月学区调整以及**“金九银十”预期带来第二波小高峰**；岁末 11-12 月稳定在 ≈ 300 套。对挂牌方而言，应避开 3-4 月的集中供应高点，以减少同质竞争；对购房者，则可在 5-8 月把握议价窗口，尤其是长时间滞销房源往往愿意下调 2 %–3 % 议价空间。



5. 小区热门度：词云映射购房者“心智地图”

词云将小区名称按挂牌频度可视化。“公寓”“城市”“之星”“两湾城”“宝华”字号最大，表明核心区小户型公寓与浦东新区大体量社区是上海市场最活跃的两端。具体来说：


- ✓ 核心 CBD 微型公寓：面积 30-50 m²，均价高但总价可控，受单身白领与投资客青睐；
- ✓ 外环-郊环大型住区：体量大、配套完善、以刚改家庭为主力，交易活跃度高。

对想快速出手的业主，选择上述热点小区可缩短成交周期 15-20 天；而购房者若对价格敏感，可在热词中避开“爆款”小区，转向同板块内长尾项目以捕捉 5 % 左右的相对洼地。

六、驱动因子探究


1. 挂牌天数×单价：流动性对价格的“乙方”影响

如图：高频密集区集中在单价 3-6 万元/m²、挂牌期 < 200 天；走势呈右上-左下微弱倾斜，说明**高单价房源平均去化更慢**。相关系数仅-0.16，表明流动性虽影响议价，但远不及区位与物理属性。对急售业主而言，把挂牌价调低 4%-6% 可将平均去化期缩短近一半；而资金链宽裕者，则可容忍 180 天以上的长挂牌以博取更高溢价。



2. 价格随区位呈明显“同心圆衰减” 横向比较内外环单价中位数，内

环内 8.1 万元/m²稳居顶点；一步跨至内环-中环带即跌至 6.0 万元/m²，降幅约 26%；中环-外环再降 18%，至郊环外仅 3.9 万元/m²。该梯度与轨交密度、商务配套及学区资源重叠度高度一致，体现了**“都市核心溢价”规律**。对自住客，跨环置业意味着相似预算获得 30%-40% 的面积增益；而对投资客，核心区稀缺性带来的低空置与高流动性，使其在长周期内优先守住账面收益。



3. 房屋类型与结构

- 板楼：中位数 ≈ 6.2 万元/m²，上四分位可冲破 10 万元/m²；大面积采光带来的居住体验与稀缺性共同推高价格。
- 框架：中位数仅 5.3 万元/m²，但低端长尾拉得更长——大量 15 年以上老公房、商住公寓将尾部拉低。


- 板塔结合：以改善盘为主，中位数 ≈ 7.2 万元/ m^2 ，上限被公摊与塔楼段数压制。

值得注意的是，**Sankey 图显示超过 70% 的精装修流向钢混结构**，而钢混在市场上普遍贴有“商品房标配”标签，反而产生 2%-3% 的隐含折价——提示高端开发应关注“外观-品质”错配带来的价值修复机会。

4. 变量交互：区-装修-结构链路映射潜在供给侧升级

Sankey 流向揭示：静安、徐汇、长宁等老牌核心区精装-钢混占比高，表面看已“卷”到极致；但流向图中宝山、闵行的简装-框架仍有 30% 以上体量，若叠加行政区“更新”政策，可通过局部加装电梯、精装升级实现价值重估——**供给侧改造而非新增土地**是稀缺年代的增量之道。


房源桑基图：区 → 装修情况 → 建筑结构



5. 面积 $\times$ 单价 $\times$ 梯户比：多维几何塑造总价分布

3D 散点与柱状体将总价分解为“面积 $\times$ 单价”并辅以梯户比。可见：

- ✓ 面积与单价的平面几乎形成一条“斜面”：解释了总价 95% 以上的方差；
- ✓ 梯户比 < 1 (两梯两户) 集中在高总价区：高端住宅更强调私密与等待成本；
- ✓ 当梯户比 > 2 时，总价分布下沉，暗合“公摊-等待”对家庭改善型客户的负效用。



6. 回归结果：面积与单价为“强引擎”，梯户比为“调味剂”

面积弹性最大（ $\beta \approx 6.5$ ），符合“限购框定面积→总价由面积直接拉升”逻辑；单价虽单位增幅小，但对核心地段高价盘具有杠杆效应；梯户比为居住舒适度 proxy，对改善-豪宅段尤其敏感。


清洗后剩余 1996 条数据

OLS Regression Results						
=====						
Dep. Variable:	总价(万元)		R-squared:		0.995	
Model:	OLS		Adj. R-squared:		0.995	
Method:	Least Squares		F-statistic:		1.385e+05	
Date:	Thu, 08 May 2025		Prob (F-statistic):		0.00	
Time:	20:23:16		Log-Likelihood:		-9207.6	
No. Observations:	1996		AIC:		1.842e+04	
Df Residuals:	1992		BIC:		1.845e+04	
Df Model:	3					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-635.2985	3.935	-161.437	0.000	-643.016	-627.581
梯户比数值	7.2107	3.249	2.220	0.027	0.839	13.582
单价(元/平)	0.0098	1.77e-05	554.628	0.000	0.010	0.010
房屋面积(平米)	6.5124	0.044	148.910	0.000	6.427	6.598
=====						
Omnibus:	270.675		Durbin-Watson:		1.795	
Prob(Omnibus):	0.000		Jarque-Bera (JB):		1423.156	
Skew:	0.524		Prob(JB):		9.24e-310	
Kurtosis:	7.002		Cond. No.		5.85e+05	
=====						

7. 综合洞察：多变量平行坐标的“三条轨”

平行坐标经归一化后露出三类走势：




- ✓ 高单价- 中面积- 低梯户比（精装板楼）：轨迹从单价高区一路平滑降至面积- 梯户低值，是典型市区改善盘；
- ✓ 中单价- 大面积- 中梯户比（框架商品房）：轨迹缓升后平移，下沉市场的主力；
- ✓ 低单价- 中面积- 高梯户比（商住公寓/老公房）：轨迹先低后骤升，持有价值与流动性双低。

投资策略可据此“三轨”匹配风险偏好：资金充裕者守一轨（资产保值），自住升级选二轨，收益追求型则择机“捡漏”三轨里短周期错位的物业。

8. 综合分析


从空间分布来看，“总价- 电梯”地图清楚地表明，**电梯配置在上海内环与中环一带几乎成为标配**，带电梯的小高层和高层大多以深绿色聚集，成交总价往往介于八百到一千二百万元之间；而**外环外的多层老公房缺少电梯**，颜色明显变浅，总价通常只有四五百万元。可以说，在地价昂贵、人口密集的核心城区，垂直交通的便捷性和居住舒适度被置于最优优先级；同一板块若缺少电梯，房源平均要比同类带电梯住宅便宜约一成，这一**“垂直通勤”溢价成为决定总价差异的重要杠杆**。




“单价- 装修”地图进一步揭示了**区位与装修的乘数效应**。内环内与沿黄浦江一线的精装修项目往往显示为深绿色，高达九至十二万元每平方米；即便同处核心区的简装修房源，也可以维持六至八万元的水平，说明地段价值能够部分抵消装修折价。相反，在郊环，精装房的单价只比简装高出约百分之五到七，天花板明显受制于宏观区位。由此可见，装修质素对价格的加成取决于其地段基础：**在高价值区域，精装放全面优势；在普通区域，装修只能带来有限增幅。**

七、交互式分析


1. 聚类散点图——总价-单价-面积两两分析



2. 各区单价在地图上的直观展示



3. 各小区单价分析：利用 Kepler 的 3D 可视化图像



广州市二手房居住情况

一、引言


广州作为中国南部的门户城市与粤港澳大湾区的核心引擎之一，长期以来在国家发展格局中占据重要地位。其深厚的商贸传统、成熟的产业基础以及不断优化的营商环境，使其不仅吸引大量人口流入，也推动了住宅市场的持续活跃。随着城市更新与轨道交通建设不断推进，广州的城市格局正从“老中心+新城带动”向“多核协同+空间重构”演进，居民的居住结构和置业选择也随之发生转变。

二、单变量分析

1. 总价分析

广州市二手房总价的五数概括如下：

- ✓ 最小值：125.00 万元
- ✓ Q1：165.00 万元
- ✓ 中位数：179.00 万元
- ✓ Q3：191.00 万元
- ✓ 最大值：430.00 万元




从箱线图来看，广州二手房的总价分布相对集中，大部分房源价格位于 165 万至 191 万元之间，表明中低总价段占据主流市场，市场亲民性较强。同时，存在一定数量的高价房源，反映出广州在局部优质地段仍有高端购房需求，如珠江新城、天河核心区等地的改善型住宅。整体上看，有较强的居住可达性。

2. 单价分析

单位面积价格的五数概括如下：

- ✓ 最小值：17,337 元/m²
- ✓ Q1：21,051.75 元/m²
- ✓ 中位数：23,004.00 元/m²
- ✓ Q3：25,004.00 元/m²
- ✓ 最大值：53,263.00 元/m²




广州的房价在单价维度呈现温和右偏分布，房屋单位面积价格总体保持在 2 万元至 2.5 万元/平之间，相比一线城市中的上海和北京略低，说明城市在核心功能区依然具有较高的房地产吸引力，但其对整体市场均价的拉动作用相对温和。

3. 房屋面积结构

房屋建筑面积的五数概括如下：

- ✓ 最小值：62.70 m²
- ✓ Q1：73.15 m²
- ✓ 中位数：77.13 m²
- ✓ Q3：81.66 m²
- ✓ 最大值：95.84 m²



广州二手房市场在房屋面积方面相对均衡，多数房源集中于 70 - 85 平方米之间，属于典型的两房或小三房配置，符合普通家庭与首次置业群体的空间需求。**与上海、北京相比，广州的住宅面积相对紧凑**，反映出其在城市开发策略中对土地利用率的考量。此外，极小或极大的面积房源较少，说明广州在二手房交易结构中，**以功能实用型产品为主导**，过大或过小面积产品的市场接受度较低。


三、多变量分析

1. “双变量”格局

从变量之间的成对关系图与热力图来看，广州市二手房价格体系呈现出典型的**“双变量主导”格局**。

(1) 总价 - 单价关系：主导趋势与价格带结构


从总价与单价的联合分布图来看，二者之间关系紧密且线性特征明显，回归线斜率稳定，表明在大多数成交样本中，房屋面积变化对总价影响相对较小，总价基本由单位价格驱动。同时，可见不同颜色的分组点密集分布在中低单价区域，高单价房源主要集中在面积较小但总价拉升的特殊板块，显示出**广州局部高价值地段中“以价控总”的普遍现象**。




(2) 总价 - 面积关系：横向集聚，纵向分散

从总价与房屋面积的散点图来看，总体上呈现出**面积集中、总价扩散的格局**。房屋面积多集中在 70 - 85 m²区间，表现为图中明显的“垂直块状结构”。而总价从 150 万到 350 万呈梯度抬升，说明面积在一定程度上受到主流户型规划限制，而总价则随单价差异形成“价值梯度”。换言之，广州二手房市场中“总价弹性”主要由地段或产品溢价推动，而非面积扩展。


(3) 单价 - 面积关系：结构性负相关与交易习惯印迹



最后，单位面积价格与建筑面积之间呈现明显负相关，这在三者关系中最具解释力。图中表现为一条左高右低的趋势线，即越小面积的房源往往具有越高的单价，背后隐含的是小户型更易进入核心地段市场、投资属性更强、需求弹性更大的现实情况。这种负相关也凸显出广州“改善型偏大、刚需型偏贵”的市场结构：大户型集中在单价较低区域，而核心区域房价高但面积小，购房者面临面积与地段的取舍。




综合来看，广州房价受单价驱动特征明显，房屋面积处于被动适配地段与预算的中介位置。总体价格逻辑体现为：单价决定总价，面积服从预算。这也解释了为何广州二手房的市场在保持总价亲民的同时，局部单价仍具强烈冲击力。



2. 核密度云与聚类分析

(1) 核密度估计：主流房源的“三集中”现象

从三幅核密度估计图可见，广州市二手房市场呈现出明显的“三集中”特征：




- ✓ 在“总价 vs 单价”图中，主密度区高度集中于总价 160–210 万元、单价 22,000–27,000 元/平区域，形成明显的椭圆密度核，表明这一价格带是市场的核心交易区间；
- ✓ “总价 vs 面积”分布显示，房屋面积高度聚集在 70–85 m² 区间，且与总价构成相对密集的交易带；
- ✓ “单价 vs 面积”关系中，核密度云沿一条“单价降低–面积增大”的负斜率通道分布，进一步印证了面积与单价之间的负相关结构。

如上信息表明：**广州二手房主流产品以“中等面积、中低总价、偏高单价”组合为主**，这既受限于购房者的**预算约束**，也反映了**城市高密度开发背景下空间与价格之间的博弈**。

（2）聚类分析：市场分层与产品定位初探

在对总价、单价和面积三维指标进行聚类后，**K-Means 模型**成功划分出三个显著的聚类组，分别代表不同层级的市场特征：




- ✧ **Cluster 0**：集中于总价 140–180 万元、单价 20,000–25,000 元/平、面积约为 65–80 m²，代表以刚需型小户型为主的主流板块，是市场的成交中坚；
- ✧ **Cluster 1**：主要分布在单价稍高（25,000–30,000 元/平）、面积偏大（75–90 m²）的区间，总价则处于中段，体现了改善型家庭或交通便利次核心区域的特征；
- ✧ **Cluster 2**：集中在单价高于 30,000 元/平，总价超过 250 万元的高位组，但面积波动较大，多分布于核心区高溢价地段，是典型的高端改善或投资类产品。

从整体看，**聚类结果与核密度估计图形成良好呼应**——广州二手房市场已形成以**“价格带+面积层”为核心的分层结构**，不同购房群体在价格、空间与区位上的权衡，正推动着市场向“精细化产品定位”和“价格敏感型分化”方向演进。

四、区级数据分析


从广州二手房的区域分布来看，房源供给、价格水平与区位价值之间存在显著差异，呈现出**中心集聚、外围平稳、极值板块突出**的多重格局。

1. 房源供给格局：天河与白云双核显现，外围区域供给稀疏




从房源数量分布图可以看出，**天河区**以超过 1700 套房源数量遥遥领先，是广州二手房市场的绝对主力，其次是**白云区与番禺区**，呈现出明显的**“双核+郊带”结构**。天河作为广州 CBD 核心，教育、医疗、商业资源密集，自然成为置业集中区。而白云近年来受益于交通改善和板块更新，也逐步走向供给活跃。相比之下，南沙、从化、增城等外围区域由于数据量较少，市场活跃度和交易密度均较低，体现出**城区发展梯度和空间层级**。

2. 单价空间分布：天河领先，荔湾、越秀紧随其后



房源单位价格对比显示，**天河区**以 **24,902 元/㎡**居首，**荔湾、越秀**分别为 **24,746 元/㎡**和 **24,588 元/㎡**，形成广州核心老城高价区三强。这些区域以教育、医疗、配套成熟著称，具备高度的资产稳定性与溢价空间。而**番禺、南沙、黄埔**等外围区则维持在 2.1–2.3 万元/㎡之间，呈现出“可负担但增长潜力较强”的特征。整体上，广州在单位面积价格上形成了**“一核多点”式的价格岛结构**，各区域之间差异显著，反映出城市功能区与交通体系对房价的强调控作用。

3. 总价对比格局：区域差距被压缩，中端市场占主导




在房源总价层面，各区差异相对缩小，大部分区域的平均总价集中在 **166万-186万元之间**，价格带相对紧凑，显示出广州整体市场以中端改善型产品为主。虽然天河、越秀等地的单价更高，但由于面积适中，其总价控制较为合理，并未形成“高不可攀”的隔离带。这种价格策略有效平衡了高地段溢价与购房预算之间的矛盾，使中心区产品仍保有一定的市场接受度。

五、离散变量分析

广州二手房市场的产品特征不仅体现在价格与面积的连续性指标上，还**深受一系列离散性变量的影响**，如装修状况、建筑结构、楼层类型等，这些因素共同构成了购房者对住宅价值认知的重要依据。


1. 装修情况：精装比例居首，体现功能导向需求



数据显示，**精装修房源占比达到40.7%**，为所有装修类型中最多，其次为“其他”（34.7%）与“简装”（23.3%），毛坯房仅占1.2%。这反映出广州买家对拎包入住的便利性需求较强，同时也可能受到部分新近房源或中介统一翻修交付的影响。总体上，精装已成为二手市场中的主流交易形态，市场趋向“交付即使用”的使用价值导向。

2. 建筑类型：板楼绝对主导，点楼为补充结构

在建筑结构上，**板楼占比高达84.3%**，点楼与板塔结合型合计仅约14%，显示出广州在普通住宅开发中对通风采光、得房率的重视。板楼结构更符合南方气候环境下的通透与舒适性，且由于广泛应用于小区刚需产品之中，其比例自然居高不下。




3. 楼层高低：中高楼层为主，适居性选择趋于理性

楼层分布方面，中楼层（38.9%）和高楼层（35.3%）占据主导，低楼层相对较少（25.8%）。这说明购房者在选择过程中更倾向于视野良好、通风采光优的楼层，但也在心理与预算之间寻找平衡，中层成为兼顾性价比与居住体验的理想选择层段。

4. 月度挂牌走势：淡季与旺季特征明显，市场交易节奏规律化

从月度挂牌趋势图中可以看到，广州二手房挂牌量呈现出**“前高后稳”的年内分布特征**，其中3月挂牌量达到峰值，随后在年中略有回落，9月后逐步回升。这一走势与传统的“金三银四”“金九银十”购房旺季相契合，反映出市场交易节奏的季节性波动，亦说明大部分房东择机入市行为较为集中。



5. 小区关键词分析：品牌与地段成为核心认知

词云图中，“花园”“城”“丽江”“亚运”“媒体”等词频较高，集中反映出广州热门小区在名称上的几个倾向：**品牌形象强（如“花园”类品质楼盘）、地段暗示明显（如“城”“江”等词表达城市核心水系区位），以及大型项目背景（如“亚运”“媒体”等源自赛事/资源配套）**。这些词汇不仅代表了房源供给集中区域，也部分反映了购房者偏好的情感认知维度。

综合上述分析知，广州二手房市场在离散属性上表现出**实用性导向、结构理性化与功能分层清晰**的特点。从产品层级结构来看，**市场已初步完成从“基础可居”向“品质可选”的升级**，购房者不仅关注价格，也逐渐重视居住体验、结构类型与产品配置。

六、驱动因子探究

1. 回归模型结果：三变量对总价解释力极强


清洗后剩余 1896 条数据

OLS Regression Results						
=====						
Dep. Variable:	总价(万元)		R-squared:	0.993		
Model:	OLS		Adj. R-squared:	0.993		
Method:	Least Squares		F-statistic:	9.126e+04		
Date:	Thu, 08 May 2025		Prob (F-statistic):	0.00		
Time:	20:37:06		Log-Likelihood:	-3663.9		
No. Observations:	1896		AIC:	7336.		
Df Residuals:	1892		BIC:	7358.		
Df Model:	3					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-190.7756	0.841	-226.837	0.000	-192.425	-189.126
梯户比数值	1.1395	0.294	3.870	0.000	0.562	1.717
单价(元/平)	0.0081	1.56e-05	518.747	0.000	0.008	0.008
房屋面积(平米)	2.3511	0.008	296.019	0.000	2.336	2.367
=====						
Omnibus:	255.534		Durbin-Watson:	1.778		
Prob(Omnibus):	0.000		Jarque-Bera (JB):	2027.802		
Skew:	0.363		Prob(JB):	0.00		
Kurtosis:	8.014		Cond. No.	5.06e+05		
=====						

从 OLS 回归结果可知，模型的决定系数（R²）高达 **0.993**，说明选取的三个变量几乎可以完全解释总价的变化。其中，**单位价格（单价）与房屋面积的回归系数分别为 0.0081 与 2.3511**，均远高于标准误，显著性（P<0.001）非常强，确认了总价主要受 **单价 × 面积** 所共同驱动。换言之，**单价作为“强度”，面积作为“体量”，两者共同构成价格空间**，验证了房地产价值的最基本逻辑结构。


2. 辅助因子：梯户比的间接影响机制



梯户比系数为 **1.1395**，在统计上亦显著，意味着随着梯户比的增大（即每部电梯服务住户数增加），房源总价也有提升趋势。尽管这一结果看似反直觉，但结合结构分析可知，该变量实际反映的是大体量新社区中“高容积、高密度、均价适中”的市场特征。即：**梯户比较高的楼栋往往配套完善、体量大、房源面积适中，总价自然集中于中间偏上段位**，从而体现了建筑配置对房价的隐性调节。

3. 可视化验证：变量关系稳定、结构趋势明显


从 3D 散点图与柱状图可以进一步确认上述模型逻辑：在相同梯户比条件下，房屋面积与单价均对总价呈现明显线性递增趋势，且面积波动对总价贡献更为直接；而梯户比在多个面积区间内显示出“平台式提升”效应，即总价在 0.85–1.25 区间随之上浮一阶。



4. 建筑类型与挂牌周期的次要影响


补充变量分析中，我们发现不同建筑类型在单价分布上略有差异，**板楼类型略高于点楼与混合结构**，可能因得房率与通风性能优势受到购房者偏好；同时，从挂牌天数与单价的六边形分布图来看，**挂牌时间与价格之间并无强线性关系**，但低单价房源集中挂牌期更长，说明中低价房在市场上具有更大的库存压力。

房源桑基图：区 → 装修情况 → 建筑结构



5. 多变量并行趋势图：市场存在“中价带聚合”现象

在归一化后的并行坐标图中，我们观察到多数样本在单价、面积与梯户比三个维度上趋于中段，且总价主要聚集在中等区间。显示出广州二手房交易中，房源配置集中于 “**中单价、中等面积、中密度**” 三类参数范围，进一步印证前文提出的市场主力结构模型。




综上，广州房价的形成机制呈现出高度可解释性与结构稳定性：**单价是总价最直接的放大因子，面积是决定交易带宽的底盘变量，而梯户比、建筑类型等则作为补充变量对房价起到结构性调节作用。**这为未来房产估值建模、风险识别与策略制定提供了可量化的路径依据。


6. 综合分析

从“**广州二手房总价与电梯配置分析**”图中可见，房源总价在空间上的分布与住宅配套设施（如电梯）密切相关。整体上看，**房源总价由内而外呈现逐步递减的空间梯度**：中心城区如天河、越秀等地段普遍高于 185 万元，而外围如从化、增城、南沙等区域则集中于 170–175 万元之间。地图中的圆点进一步细分房源为“有电梯”与“无电梯”两类，结果表明：**绝大多数总价较高的房源均为“有电梯”配置**，而无电梯房源更多出现在老旧小区或外围地段，且价格整体偏低。这一现象说明，在广州住宅市场中，电梯作为重要的基础配套设施，已经成为影响房屋价值的重要指标，体现出购房者对生活便利性与建筑舒适性的现实需求。

广州市二手房总价与电梯配置分析



广州市各区二手房单价与装修情况分析




而在“各区二手房单价与装修情况分析”图中，广州市房源单价同样呈现“中心高、边缘低”的分布特征。越秀、荔湾、天河等传统城区均价高达 24000 元/㎡以上，而外围区域单价则多集中在 21000–22000 元/㎡区间。同时，图中通过圆点颜色区分装修类型，发现：**精装修房源主要集中在单价较高的区域，而简装修房源则更多出现在中低价板块**。这说明房源的装修质量在一定程度上与房屋价格协同提升，即**高单价房源往往匹配更高标准的装修状态**，形成价值闭环。消费者对于“即买即住”“减少翻新成本”的需求在市场中被有效响应，也反映出广州二手房市场的产品升级趋势。

两张地图从住宅“配套设施”和“内部装修”两个层面揭示出：**配套完善、装修良好与房价水平之间存在显著共振关系**，而广州的房价梯度不仅受地理位置影响，也受到产品属性与舒适性标准的持续推动。核心城区凭借优质配置实现价值稳固，而外围板块则依赖配套改善与产品提升逐步缩小价格差距，这正是广州城市居住空间不断演进的缩影。


七、交互式分析

1. 聚类散点图——总价-单价-面积两两分析


交互式可视化图以动态映射方式揭示了广州房价结构中单价、总价与面积三者之间的关键关系，不仅展现了单价与总价的强正相关、单价与面积的负相关趋势，也通过区域颜色编码使用户能够直观对比各区表现差异。与静态图相比，交互式图表允许用户聚焦特定区域、区间或变量组合，自主筛选并深入观察不同房价层级背后的变量联动，从而更高效地识别热点区、结构性异常与价格驱动逻辑。这种可操作的探索体验极大提升了数据分析的灵活性与洞察深度，是辅助城市住房研究与市场决策的重要工具。



2. 各区单价在地图上的直观展示



3. 各小区单价分析：利用 Kepler 的 3D 可视化图像



深圳市二手房居住情况

一、引言


深圳作为中国改革开放的窗口和粤港澳大湾区的核心引擎之一，自设立经济特区以来，深圳经历了从“**边陲小镇**”到“**国际都市**”的跃迁，吸引了大量高素质人才和资本持续流入，也促使住房市场长期保持高热度。在空间格局方面，深圳正由“**原特区内核心区主导**”逐步演变为“**多中心驱动+轴带联动**”的**都市圈结构**，体现出强烈的结构转型特征。

二、单变量分析

1. 总价分析

深圳二手房的总价分布明显高于广州，其五数概括如下：

- ✓ 最小值：77.00 万元
- ✓ Q1：330.00 万元
- ✓ 中位数：459.00 万元
- ✓ Q3：690.00 万元
- ✓ 最大值：5800.00 万元




从箱线图可以看出，深圳总价**分布的跨度非常大**，数据**整体右偏**，表现出强烈的“**高价房长尾**”特征。在主流交易区间内，属于高总价段房源，在全国范围内亦属顶尖水平，体现出深圳作为科技型移民城市所催生的强烈购房需求与支付能力。超过 1000 万的房源集中于少数核心片区，形成明显的**市场极化现象**。

2. 单价分析

深圳单位面积价格的五数概括如下：

- ✓ 最小值：20,156 元/m²
- ✓ Q1：40,382 元/m²
- ✓ 中位数：53,410 元/m²
- ✓ Q3：73,564 元/m²
- ✓ 最大值：299,676 元/m²




深圳房价单价分布右偏较为明显，大量房源集中在 4-7 万元/平区间，属于全国最高水平之一。部分房源单价甚至突破 20 万元/m²，极值向上严重拉伸，主要为豪宅项目所致，反映出深圳**住房市场高度金融化与资产属性显著**的特点。

3. 房屋面积结构

深圳房屋面积的五数概括如下：

- ✓ 最小值：29.31 m²
- ✓ Q1：85.04 m²
- ✓ 中位数：88.58 m²
- ✓ Q3：89.94 m²
- ✓ 最大值：448.78 m²




从箱线图来看，深圳房源面积分布集中度极高，绝大部分交易集中于 85–90 平米之间，说明**二手房市场中以实用型、紧凑型三房为主流**，占据主导地位。这种高度集中的面积配置背后，反映出开发商在商品房设计上对户型效率的极致压缩，也说明在高房价背景下，购房者更倾向于选择**性价比高、总价控制合理的产品**，适配其年轻化、高流动性的人口结构。


三、多变量分析

1. 变量间联动关系分析

首先，从**成对关系图**可以清晰看到，总价与单价、总价与房屋面积之间均表现出较强的正相关性，呈现**明显的线性趋势**。而单价与面积的关系则更为复杂，散点分布较为分散，存在一定程度的反向倾斜与局部聚集。进一步结合热力图的相关系数数据可以量化上述观察：总价与单价的相关系数为 **0.83**，与面积的相关系数为 **0.75**，表明两者对总价具有显著解释力；而单价与面积的相关性仅为 **0.36**，呈现弱相关甚至在高端区间存在一定负相关。




从回归分析图看，总价对单价和面积均呈现出强劲的线性回归趋势，并在主流房价区间内保持**相对稳定的拟合带宽**。这说明在深圳住房市场中，总价基本可视为单价与面积的乘积结果，但在中高端市场，单价对总价的弹性更高，即**“单价主导型定价”趋势明显**。此外，回归图还揭示了一些极值点——如高总价但中等单价的房源，或超高单价却面积较小的房源，这类样本往往集中于核心区豪宅或学位房市场，体现出特定功能属性对价格的二次拉升作用。




回归发现非常接近线性关系，因此再上面没有采用默认散点图的方式，而是使用
`sns.jointplot(x='总价(万元)', y='单价(元/平)', data=data1, kind='reg', color='hotpink')`

尤其值得关注的是多色散点回归图带来的洞察。在“总价 vs 单价”和“总价 vs 面积”的图像中，颜色深浅代表了单价或面积的差异，进一步强调了**深圳楼市结构的“双驱动”格局——既有依赖单价抬升的高端产品，也有靠面积扩张支撑总价的改善型住宅**。而“单价 vs 面积”图中，随着单价上升，面积在中低段趋于收缩，反映出高房价下的“压缩式居住”现象，即高净值购房者为保核心地段而牺牲面积。




综合来看，深圳房价形成机制体现出**高度的市场效率和显著的结构分化特征**：在总价维度上，单价是第一主导因子，面积在高端市场则体现出“可牺牲性”；而在中端市场，两者共同主导定价逻辑。此外，由于政策、学位、地段等附加价值未在数值型变量中体现，其对回归曲线的局部“偏移”也提示未来研究需引入更多维度变量，如房龄、物业类型、地铁距离等，以实现更精细的估价建模。

总价(万元) vs 单价(元/平)核密度估计图




2. 核密度云与聚类分析

为进一步揭示深圳二手房市场中价格分布的空间聚集特征及结构性异质性，本部分结合核密度估计图与聚类分析结果展开探讨，从**二维分布和簇群分解**两个角度理解深圳房价的潜在结构逻辑。



从核密度估计图来看，“**总价 vs 单价**”的分布呈现出**高度集中的“主核区”**，大致位于总价 500–1500 万元、单价 5–10 万元/m²之间，这一区域形成价格密度最高的交易热带，表明大量交易集中于中高端改善型住房市场，具备高度稳定性。而在“**总价 vs 面积**”图中，面积集中在 80–120 m²、对应总价集中在 500–1200 万元的区域为密集核，这与上一图一致地指向深圳市场以功能性三房为主流构成。相比之下，“**单价 vs 面积**”图中的**密度云呈现出更加分散且向右下倾斜的趋势**，说明在高单价段内，房屋面积呈现压缩趋势，显示出高房价压制下的居住空间牺牲现象，即“高单价-小户型”结构。

进一步引入 **K-Means 聚类算法**，将全部房源数据在三维空间中分为三类，识别出深圳房价市场的潜在分层格局。从聚类结果看：




- ✧ Cluster 0 代表**主流刚需市场**，该类房源总价多集中在 300–800 万元，单价在 4–7 万元/m²，面积偏小但集中（80–100 m²），广泛分布于非核心区及部分郊区片区，如龙岗、宝安部分区域等；
- ✧ Cluster 1 对应**中高端改善市场**，表现为总价上浮（800–1500 万），单价与面积均有一定提升，集中于次中心如前海、华强北及罗湖传统片区；
- ✧ Cluster 2 明显**偏离主流市场**，属于豪宅及顶级物业区，单价高达 15 万/m²以上，总价常突破 2000 万，面积多大于 150 m²，主要集中在香蜜湖、深圳湾、南山科技园周边，具备强烈的地段溢价与资本属性。

这一聚类结果进一步印证了深圳房地产市场的“三段式结构”特点，即**刚需主导+改善过渡+极高端分化**，反映出该城市房价体系的高度结构化与分层运行机制。特别是高端簇的存在，揭示出土地稀缺性与资产投资功能对房价的强力驱动，进而对中低端市场产生挤出效应。

四、区级数据分析


从区域维度来看，深圳各行政区在房源数量、均价水平以及总价结构上呈现出**明显的分层与梯度特征**，揭示了城市空间结构对住房市场的深度塑形。

1. 房源供给格局：龙岗、南山领跑，福田、宝安构成中轴核心




从房源数量分布图可见，**龙岗区**以 887 套房源位列全市第一，成为深圳二手房市场的“供应大仓”，紧随其后的是**南山区和宝安区**。这三大区域共同构成**深圳住房市场的核心供给带**。其中，龙岗凭借广阔的土地资源和较低的房价门槛，承载大量刚需和外来人口；南山因科技产业聚集、高校资源丰富，吸引大量高净值人群；宝安则在深港西部通道与前海自贸区带动下，形成西部置业热带。与之相对，盐田、大鹏等区域房源较为稀缺，反映出区域发展阶段与人口密度的差异。

2. 单价空间分布：南山、福田双核高价区引领，形成价格极核



在单位面积价格方面，**南山区**以 103,049 元/㎡高居榜首，**福田区**以 94,847 元/㎡紧随其后，**二者共同构建深圳二手房市场的“价格极核”**。这一区域集聚了深圳的金融、科技与优质教育资源，地段溢价能力极强，成为全市最具资产属性与保值能力的住宅片区。其次为罗湖与盐田，虽为传统老区，但因生活配套成熟，仍维持较高单价。而坪山、大鹏、光明等边缘区域则有较强的价格亲和力与改善潜力。整体上呈现出明显的**“高端极核+外围洼地”结构**，房价受地段驱动显著。

3. 总价对比格局：高低分化显著，购房门槛呈现阶梯式跃升




在总价维度上，南山区以 1,330.42 万元的平均总价一骑绝尘，福田区与罗湖区位列其后，三者形成深圳房价的第一梯队，门槛极高，凸显其区域房产金融化和投资属性强烈。而坪山、光明、大鹏等区的平均总价仍处于 300–400 万元区间，是全市最具刚需承载能力的区域。相较于广州“总价差异缩小”的特征，深圳各区总价呈现出更大的拉锯与跃迁，显示出城市内部的显著分层结构，也对购房群体形成分化考验。总体而言，深圳市场结构趋于“多层次+极端分化”的组合，购房选择日益依赖支付能力与区域偏好之间的权衡。

五、离散变量分析

在对深圳二手房市场的离散型变量进行统计分析时，维度涵盖了装修状况、建筑类型、楼层高低、月份上架节奏与小区名称词频等多个方面。通过这些变量的分布特征，可以补充理解房价背后的产品结构与市场偏好。

1. 装修状况：精装占比过半，体现市场对入住便利性的偏好

数据显示，约有 50.2% 的房源为精装修产品，简装与毛坯则分别占比 14.4% 与 2.7%，还有 32.7% 未标明或为其他类型。精装修房源的主导地位说明深圳购房者在高房价、高节奏的城市生活背景下更偏好拎包入住型产品，开发商与业主也更多选择提供装修完备的房源以增强吸引力。



2. 建筑类型：板塔结合为主流，纯板楼稀缺

建筑类型方面，深圳二手房以板塔结合结构为主，占比达 54.1%，其次是塔楼结构 33.5%，而传统纯板楼占比仅为 11.2%。这种结构趋势反映出深圳土地高密度开发与容积率利用最大化的策略导向，虽然塔楼视野开阔，但板塔结合结构在通风、采光等方面更具平衡性，成为城市商品房设计的现实妥协。




3. 楼层结构：中高层占主导，低密产品占比下降

从楼层高度分布看，中楼层与高楼层基本持平，低楼层占比略低。这与深圳楼宇普遍较高、住宅密度大有关，反映出城市发展水平较高、住宅产品向立体化演进的趋势。高层住宅虽对部分购房者存在心理门槛，但因视野与私密性优势，仍具较强市场认可度。

4. 月度供给节奏：年初冲量，年中低谷，三季度恢复活跃

从房源上架时间来看，市场供给呈现出一定季节性规律：**3月与4月为全年最活跃月份**，明显高于其他月份，反映出“春节后换房潮”带动下的集中放盘现象；而**6-7月**期间交易热度趋冷，可能受天气与毕业季等因素影响；**9月起**再次升温，延续至年底。整体趋势说明深圳房地产市场具有明确的时间窗口期特征，购房策略和推盘节点需考虑季节因素。



5. 小区关键词分布：品牌房企集中，叠字+期数命名高频

从词云图可以看出，“花园”“中心”“一期”“金御”“信义”等词汇频繁出现，呈现出**品牌集群+产品命名统一化**的趋势。大量小区名称带有“期”字，说明深圳项目开发多采用分期滚动模式；而“中心”“星河”“金域”等高频词反映出房企在营销命名上倾向于突出地段价值与品质感，品牌效应与心理认知对市场交易的影响显著。

六、驱动因子探究

为了深入理解深圳二手房总价的形成机制，本部分聚焦于关键变量对房价的驱动作用，通过回归模型、三维图、分组比较等多维视角，对**单价、面积、梯户比等变量**的相互影响进行系统分析。

1. 回归结果揭示核心驱动因素：面积与单价双主导，梯户比辅助

清洗后剩余 2317 条数据

OLS Regression Results						
=====						
Dep. Variable:	总价(万元)		R-squared:		0.938	
Model:	OLS		Adj. R-squared:		0.938	
Method:	Least Squares		F-statistic:		1.160e+04	
Date:	Thu, 08 May 2025		Prob (F-statistic):		0.00	
Time:	20:50:18		Log-Likelihood:		-14689.	
No. Observations:	2317		AIC:		2.939e+04	
Df Residuals:	2313		BIC:		2.941e+04	
Df Model:	3					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-942.1522	10.097	-93.313	0.000	-961.952	-922.353
梯户比数值	130.1158	16.007	8.129	0.000	98.726	161.506
单价(元/平)	0.0106	9.75e-05	109.107	0.000	0.010	0.011
房屋面积(平米)	8.8103	0.105	83.604	0.000	8.604	9.017
=====						
Omnibus:	2127.122	Durbin-Watson:		1.885		
Prob(Omnibus):	0.000	Jarque-Bera (JB):		307768.331		
Skew:	3.809	Prob(JB):		0.00		
Kurtosis:	58.946	Cond. No.		4.15e+05		
=====						


从多元线性回归结果来看，模型对总价的解释力极高，说明变量选择较为合理。其中，**单位面积价格和房屋建筑面积对总价均呈显著正相关：**

- ✓ 每增加 1 元/m²，总价平均提升 0.0106 万元（即 10.6 元）；
- ✓ 每增加 1 m²面积，总价平均增长 8.81 万元。

此外，梯户比作为建筑配置指标，也表现出显著影响，即每提高一个单位梯户比，总价平均增加 130 万元，提示高梯户比住宅往往属于中高端社区，具备较强的市场溢价能力。


2. 核心三因子三维交互：面积主导定价空间，单价拉开阶梯

三维散点图展示了**房屋面积、单价与梯户比共同对总价的交互作用**。其中，随着房屋面积增加，总价稳步提升，形成“面价并进”的定价面板。而在相似面积区间内，单价的拉伸效果更为明显，高单价房源显著抬升总价，尤其在深圳湾、香蜜湖等区域体现为典型特征。此外，3D 柱状图也进一步验证了这一趋势，高梯户比+大面积组合构成深圳高价房的典型模式。




3. 环线位置影响：城市核心区形成价值锚点

从环线对比结果来看，**市内环以内房源单价显著高于外围区**，中环至外环之间的价格则居中。数据说明城市交通圈层对房价具有明显调控作用，内环代表老牌核心区（如福田中心、南山科技园等），具备配套齐全、资源集中优势，而外围房源虽面积可能更大，但单价和总价普遍偏低，形成**“外扩型刚需洼地”**。



4. 建筑类型影响：板楼房源略具价格优势


从建筑类型对比箱线图看，板楼产品在中位单价上略高于塔楼与板塔结合结构，反映出其在通透性、得房率及居住舒适度方面的市场偏好；而塔楼类因设计密度高、梯户比大，在中低端项目中更为常见。板塔结合作为城市主流产品，其价格中位略低，但分布范围广，构成深圳楼市的重要中坚。



5. 时间与流动性：挂牌天数与价格呈负相关趋势


从挂牌天数与单价六边形图来看，绝大多数房源集中于挂牌 200 天以内，单价以 5-8 万元/m²为主。随着挂牌时间延长，价格密度显著降低，表明市场对价格不合理房源反应冷淡，具备明显的价格敏感性。此现象也反映出**深圳房地产市场较强的流动性与价格发现机制**。

房源桑基图：区 → 装修情况 → 建筑结构



6. 房源结构流向：各区装修与结构差异构成分化路径

桑基图展示了**各行政区之间在装修类型与建筑结构上的流向关系**。例如，南山与福田区域以精装修+钢混结构占主导，而龙岗与宝安则有较多简装及板塔类建筑，这种组合特征不仅影响价格，也决定了不同购房人群的市场偏好与选择逻辑。




7. 多变量平行坐标图：价格组差异清晰，高价房拉距强烈

最后，标准化后的平行坐标图揭示了**不同总价组在多个变量维度上的特征轨迹**。高价组整体在单价、面积与梯户比上均处于高位，轨迹斜率明显，而中低价组则分布较为集中，进一步验证了市场分层特性。

8. 综合分析

从深圳各区二手房**总价与电梯配置**的空间可视化来看，房价高低与基础设施的完备程度存在明显关联。地图显示，总价高的区域集中于南山、福田、罗湖等市区西南部，这些区域不仅拥有核心商务区、科技产业聚集带，更在小区设施方面具备更强的现代化程度——其中**有电梯配置的房源占比显著更高**。电梯配置既反映楼栋高度和建设年代，也在一定程度上体现居住便利性与产品品质，是中高端楼盘的重要标配。




进一步结合**各区房源单价与装修情况的分析图**，可以看到房屋**装修水准与价格层级之间呈现出鲜明的对应关系**。南山、福田等高单价区域，精装修房源占比突出，说明市场主力偏向高品质成品住宅；而在东部与北部的边缘区域，更多房源以“其他装修”（如简装、毛坯）为主，单位价格显著较低。这反映出房价并非单一由区位决定，**装修程度作为居住舒适度与价值附加的重要体现，也在市场中形成了溢价维度**。特别是在高房价的核心区，装修已不仅是附加值，更是产品竞争力的体现。

七、交互式分析

1. 聚类散点图——总价-单价-面积两两分析



2. 各区单价在地图上的直观展示



3. 各小区单价分析：利用 Kepler 的 3D 可视化图像

